AUDIT REPRODUCIBILITY DAN KUALITAS DATA PADA REGRESI BAYESIAN UNTUK PREDIKSI HAMBATAN RESIDU KAPAL LAYAR (STUDI KASUS: YACHT HYDRODYNAMICS)

Ditujukan untuk Memenuhi Tugas Project Mata Kuliah Analisis Regresi Tingkat Lanjut

Dosen Pengampu:

Dr. I Gede Nyoman Mindra Jaya, S.Si., M.Si.



Disusun Oleh:

Yaafi Ferdian Syahputra (140720260018)
I Gusti Bagus Harya Putra (140720260016)

PROGRAM STUDI MAGISTER STATISTIKA TERAPAN
DEPARTEMEN STATISTIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS PADJADJARAN
TAHUN 2026

DAFTAR ISI

BAB 1. PENDAHULUAN **3**

1.1 Latar Belakang Masalah 3

1.2 Rumusan Masalah 3

1.3 Tujuan Penelitian 3

1.4 Unit Analisis dan Estimand 3

BAB 2. TINJAUAN PUSTAKA **4**

2.1 Hambatan Residu dan Froude Number 4

2.2 Regresi Bayesian 4

2.3 Komputasi dan Diagnostik MCMC 4

2.4 Model Checking dan Perbandingan Model 4

2.5 Reproducibility dan Kebocoran Data 5

BAB 3. METODOLOGI **5**

3.1 Sumber Data dan Variabel 5

3.2 Audit Kualitas Data dan Preprocessing 5

3.3 Spesifikasi Model 5

3.4 Prior 6

3.5 Komputasi dan Validasi 6

3.6 Audit Reproducibility dan Skema Validasi 6

BAB 4. HASIL DAN PEMBAHASAN **7**

4.1 Audit Kualitas Data 7

4.2 Prior Predictive Check 7

4.3 Validasi Komputasi 8

4.4 Baseline M0 dan Diagnosis Kegagalannya 9

4.5 Model Remedi dan Diagnostik Konvergensi 11

4.6 Perbandingan Model: PSIS-LOO dan WAIC 12

4.7 Model Checking dan Posterior Model Final (M6) 12

4.8 Prediksi untuk Desain Lambung Baru 15

4.9 Analisis Sensitivitas 16

4.10 Audit Reproducibility 19

BAB 5. KESIMPULAN DAN SARAN **23**

5.1 Kesimpulan 23

5.2 Keterbatasan 23

5.3 Saran dan Pengembangan 23

DAFTAR PUSTAKA **24**

ACKNOWLEDGEMENT **24**

LAMPIRAN **24**

ABSTRAK

Prediksi hambatan residu (*residuary resistance*) kapal layar pada tahap desain awal penting untuk menaksir kebutuhan daya propulsi. Penelitian ini menjawab pertanyaan: *seberapa stabil dan informatif hasil Regresi Bayesian pada data Yacht Hydrodynamics ketika difokuskan pada reproducibility dan kualitas data?* Data terdiri atas 308 uji *towing tank* dari 22 bentuk lambung $\times$ 14 Froude number. Analisis mengikuti *Bayesian workflow*: audit data, prior predictive check, validasi komputasi (analitik, Gibbs, dan HMC), tujuh model bertahap (M0–M6), diagnostik MCMC, *posterior predictive check*, PSIS-LOO dengan koreksi Jacobian, analisis sensitivitas, serta audit reproducibility (seed, urutan data, dan skema validasi). Komputasi **stabil secara substantif**: posterior MCMC cocok dengan solusi analitik, dan probabilitas eksedans prediktif hanya bervariasi 0.757–0.765 antar lima seed. Uji formal $|z| < 3$ MCSE menandai SD efek hull; audit lima seed menunjukkan penyebabnya adalah MCSE yang meremehkan variasi antar-run ($0.5\times$), bukan non-determinisme. Sebaliknya, keputusan **kualitas data dan preprocessing mendominasi hasil**: model Gaussian pada skala mentah (M0) konvergen sempurna namun salah spesifikasi (27% replikasi bernilai negatif), dan RMSE validasi per-hull turun dari 8.87 (M0) menjadi 1.87 (M3). Validasi acak per baris **melebih-lebihkan** kinerja model hierarkis sebesar 63.4 ELPD (SE 11.7) dan mengubah model yang terpilih. Model informatif untuk prediksi (cakupan interval prediksi 95% per-hull M3 = 0.94; M6 sedikit konservatif, 0.99), tetapi arah efek masing-masing rasio geometri tidak dapat dipastikan dari 22 hull.

Kata Kunci: Regresi Bayesian, Reproducibility, Kualitas Data, PSIS-LOO, *Data Leakage*, Yacht Hydrodynamics.

BAB 1. PENDAHULUAN

1.1 Latar Belakang Masalah

Hambatan residu per satuan berat displacement adalah komponen hambatan kapal di luar gesekan, terutama akibat pembentukan gelombang. Nilainya menentukan kebutuhan daya propulsi, sehingga prediksi yang akurat pada tahap desain awal sangat bernilai. Dataset *Delft Systematic Yacht Hull Series* (UCI ID 243) memuat hasil uji *towing tank* untuk 22 bentuk lambung yang diturunkan dari satu *parent hull* (Standfast 43), masing-masing diuji pada 14 kecepatan (Froude number).

Regresi Bayesian menawarkan kuantifikasi ketidakpastian penuh melalui distribusi posterior dan posterior predictive. Namun, hasil Bayesian **bersyarat pada model, prior, data, dan komputasi**. Kesalahan kecil pada kualitas data atau preprocessing — misalnya skala prior yang tidak sesuai, transformasi target, atau skema validasi yang bocor — dapat menghasilkan kesimpulan yang tampak meyakinkan ($\hat{R} = 1.00$, tanpa divergensi) tetapi keliru. Karena itu, fokus project ini adalah **reproducibility dan kualitas data**: seberapa stabil hasil terhadap sumber variasi yang seharusnya tidak berpengaruh, dan seberapa besar pengaruh keputusan data terhadap kesimpulan.

1.2 Rumusan Masalah

Pertanyaan utama: **Seberapa stabil dan informatif hasil Regresi Bayesian pada Yacht Hydrodynamics ketika difokuskan pada reproducibility & data quality?** Pertanyaan ini dijabarkan menjadi empat pertanyaan terukur:

1. Apakah kesimpulan berubah bila seed MCMC atau urutan baris data diubah? (ukuran: selisih posterior dalam satuan MCSE)
2. Seberapa besar dampak preprocessing (target mentah vs log, bentuk fungsi Froude) terhadap kecocokan dan prediksi? (ukuran: ELPD, RMSE, cakupan interval prediksi)
3. Seberapa optimis validasi acak per baris dibanding validasi per hull? (ukuran: selisih ELPD dan RMSE *out-of-sample*)
4. Seberapa sensitif posterior dan kesimpulan prediktif terhadap pilihan prior yang masih masuk akal?

1.3 Tujuan Penelitian

1. Mengaudit struktur dan kualitas data, termasuk ketergantungan observasi dalam satu hull.
2. Membangun baseline Regresi Bayesian yang benar dan reproducible, lalu memperbaikinya secara bertahap sesuai temuan diagnostik.
3. Mengukur stabilitas hasil terhadap seed, urutan data, prior, preprocessing, dan skema validasi.
4. Mengomunikasikan ketidakpastian estimasi dan prediksi untuk desain lambung baru.

1.4 Unit Analisis dan Estimand

Elemen	Keterangan
Unit observasi	Satu uji *towing tank*: satu bentuk lambung pada satu Froude number
Outcome	Hambatan residu per satuan berat displacement (adimensional)
Prediktor	5 koefisien geometri lambung + Froude number; semua tersedia saat desain, sehingga tidak ada kebocoran dari outcome

Elemen	Keterangan
Estimand utama	Posterior predictive distribution $p(\tilde{y} \mid \tilde{x}, y)$ untuk **lambung baru**
Estimand sekunder	Efek 1 SD geometri terhadap resistance; stabilitas kesimpulan terhadap sumber variasi

BAB 2. TINJAUAN PUSTAKA

2.1 Hambatan Residu dan Froude Number

Froude number $Fr = V/\sqrt{gL}$ adalah kecepatan tak berdimensi relatif terhadap panjang kapal. Pada Fr rendah hambatan residu kecil. Mendekati $Fr \approx 0.4$, kapal "terjebak" di antara gelombang haluan dan buritannya sendiri sehingga hambatan meningkat hampir eksponensial (Gerritsma dkk., 1981). Konsekuensinya bagi pemodelan: hubungan outcome–Froude sangat non-linear, dan variasinya membesar pada kecepatan tinggi.

2.2 Regresi Bayesian

Inferensi Bayesian memperbarui pengetahuan melalui teorema Bayes:

$$p(\theta \mid y) = \frac{p(y \mid \theta)\, p(\theta)}{p(y)} \propto p(y \mid \theta)\, p(\theta).$$

Untuk regresi Gaussian $\mathbf{y} \mid \beta, \sigma^2 \sim N(\mathbf{X}\beta, \sigma^2\mathbf{I})$ dengan prior konjugat Normal–Inverse-Gamma $\beta \mid \sigma^2 \sim N(\mathbf{m}_0, \sigma^2\mathbf{V}_0)$ dan $\sigma^2 \sim IG(a_0, b_0)$, posterior tersedia dalam bentuk tertutup (Hoff, 2009):

$$\mathbf{V}_n = (\mathbf{V}_0^{-1} + \mathbf{X}^\top\mathbf{X})^{-1}, \quad \mathbf{m}_n = \mathbf{V}_n(\mathbf{V}_0^{-1}\mathbf{m}_0 + \mathbf{X}^\top\mathbf{y}), \quad a_n = a_0 + \tfrac{n}{2}, \quad b_n = b_0 + \tfrac{1}{2}\left[\mathbf{y}^\top\mathbf{y} + \mathbf{m}_0^\top\mathbf{V}_0^{-1}\mathbf{m}_0 - \mathbf{m}_n^\top\mathbf{V}_n^{-1}\mathbf{m}_n\right].$$

Prediksi untuk data baru memakai posterior predictive distribution $p(\tilde{y} \mid y) = \int p(\tilde{y} \mid \theta)\, p(\theta \mid y)\, d\theta$, yang menggabungkan ketidakpastian parameter dan variasi observasi. Prior yang baik ditentukan pada skala yang bermakna dan dievaluasi dengan **prior predictive check**: $\theta^{(s)} \sim p(\theta)$, lalu $y^{(s)} \sim p(y \mid \theta^{(s)})$ (Gelman dkk., 2020).

2.3 Komputasi dan Diagnostik MCMC

Model non-konjugat diestimasi dengan Hamiltonian Monte Carlo (NUTS) melalui Stan/`brms` (Bürkner, 2017). Konvergensi dinilai bersama-sama: $\hat{R}$ ter-normalisasi rank 1.01, *effective sample size* (bulk & tail) 400, tanpa *divergent transitions*, serta trace/rank plot (Vehtari dkk., 2021). Galat Monte Carlo diukur dengan $MCSE \approx SD/\sqrt{ESS}$.

2.4 Model Checking dan Perbandingan Model

Posterior predictive check (PPC) membandingkan statistik data teramati dengan data replika $y^{rep} \sim p(y^{rep} \mid y)$ untuk menemukan aspek data yang gagal direproduksi model. Perbandingan prediktif memakai $\mathrm{ELPD}_{LOO} = \sum_i \log p(y_i \mid y_{-i})$ yang diaproksimasi PSIS-LOO dengan diagnostik Pareto-k (Vehtari dkk., 2017). ELPD hanya sah dibandingkan bila semua model mendefinisikan densitas untuk variabel yang sama. Jika target ditransformasi $z = g(y)$, densitas dipindahkan ke skala y dengan koreksi Jacobian: $\log p(y) = \log p(z) + \log|dz/dy|$.

2.5 Reproducibility dan Kebocoran Data

Hasil reproducible berarti dapat direplikasi dari data mentah dan kode tanpa langkah manual: seed, versi perangkat lunak, dan preprocessing tercatat. Pada data berkelompok, validasi acak per baris menempatkan observasi dari kelompok yang sama di data latih dan uji, sehingga model "mengenal" kelompok yang diuji (*data leakage*). Estimasi kinerja menjadi terlalu optimis bila tujuannya memprediksi kelompok baru (Roberts dkk., 2017).

BAB 3. METODOLOGI

3.1 Sumber Data dan Variabel

Data sekunder berasal dari UCI Machine Learning Repository (ID 243, *Yacht Hydrodynamics*), hasil eksperimen Delft Ship Hydromechanics Laboratory. File mentah tidak memiliki header, sehingga nama kolom diberikan mengikuti urutan dokumentasi resmi.

Table 1: Tabel 3.1 Variabel Penelitian (semua adimensional)

No	Kode	Variabel	Peran
1	LCB	Longitudinal position of the center of buoyancy	Prediktor (geometri lambung)
2	Prismatic_Coef	Prismatic coefficient	Prediktor (geometri lambung)
3	LD_Ratio	Length-displacement ratio	Prediktor (geometri lambung)
4	BD_Ratio	Beam-draught ratio	Prediktor (geometri lambung)
5	LB_Ratio	Length-beam ratio	Prediktor (geometri lambung)
6	Froude_No	Froude number	Prediktor (kondisi uji)
7	Resistance	Residuary resistance per unit weight of displacement	Outcome

3.2 Audit Kualitas Data dan Preprocessing

Audit meliputi tipe dan rentang nilai, *missing value*, duplikasi, struktur hull, distribusi target, dan outlier (IQR). Preprocessing dilakukan secara eksplisit dalam satu fungsi (`make_frames`): prediktor distandardisasi $z = (x - \bar{x})/s$, target diberi dua versi (terstandardisasi pada skala mentah, dan $\log(1 + y)$ terstandardisasi), serta basis B-spline kubik (df = 6) untuk Froude. **Statistik standardisasi dan knot spline selalu dihitung dari data latih saja**, lalu diterapkan ke data uji.

3.3 Spesifikasi Model

Tujuh model dibangun bertahap. Setiap model mengubah satu aspek dari model sebelumnya, sehingga dampaknya dapat diatribusikan.

Table 2: Tabel 3.2 Model yang Dibandingkan

Model	Deskripsi	Perubahan
M0	M0 Baseline: Gaussian, raw target (Variant 1)	Baseline: Gaussian, target mentah, linear
M1	M1 Log target, linear (Variant 2)	Target log(1+y) (Varian 2)
M2	M2 Log target + Froude^2, ^3 (Variant 3)	M1 + Froude^2, Froude^3 (Varian 3)
M3	M3 Log target + Froude spline	Spline B untuk Froude
M4	M4 M3 + heteroskedastic sigma(Froude)	M3 + log sigma = g0 + g1 z_Froude (heteroskedastik)
M5	M5 M3 with Student-t likelihood	M3 dengan likelihood Student-t

Model terlengkap (M6) ditulis sebagai:

$$\ell_{ih} \sim N(\mu_{ih}, \sigma^2_{ih}), \qquad \mu_{ih} = \beta_0 + \sum_{j \in \text{geom}} \beta_j z_{j,h} + \sum_{k=1}^{6} \alpha_k B_k(z_{F,i}) + u_h, \qquad \log \sigma_{ih} = \gamma_0 + \gamma_1 z_{F,i}, \qquad u_h \sim N(0, \sigma^2_{hull}),$$

dengan ℓ_{ih} adalah $\log(1 + \text{Resistance})$ terstandardisasi dan B_k basis B-spline.

3.4 Prior

Semua prior didefinisikan pada skala terstandardisasi dengan parameterisasi eksplisit, lalu divalidasi dengan prior predictive check pada **satuan asli** Resistance.

Table 3: Tabel 3.3 Prior, Parameterisasi, dan Alasan Substantif

Parameter	Prior	Alasan
Intercept	Normal(0, 1)	Outcome terstandardisasi: di rata-rata prediktor, outcome sekitar 0 plus-minus 2 SD
Slope geometri (5)	Normal(0, 0.5)	22 hull adalah perturbasi kecil di sekitar satu parent hull; regularisasi ridge
Slope Froude (F, F^2, F^3)	Normal(0, 1)	Kecepatan adalah penggerak hambatan yang dominan secara fisik
Koefisien spline (6)	Normal(0, 1.5)	Koefisien B-spline = tinggi kurva relatif, rentang log-resistance sekitar 3.4 SD
sigma (homoskedastik)	Exponential(rate = 1)	Menjamin sigma > 0; residual SD tidak melebihi SD outcome
log-sigma: gamma0, gamma1	Normal(-1.5, 0.75); Normal(0, 0.5)	Median sigma = 0.22 SD (95%: 0.05-0.97); perubahan varians per SD Froude moderat
nu (Student-t)	Gamma(shape = 2, rate = 0.1)	Mean 20; mengizinkan ekor berat hingga hampir Normal
sd hull	Half-Normal(0, 0.25)	Selisih antar-hull pada geometri sama kurang dari sekitar 0.5 SD

3.5 Komputasi dan Validasi

Model di-fit dengan `brms` (Stan, NUTS): 4 chains × 1000 draws setelah 1000 warm-up, `adapt_delta` = 0.95, seed = 2026. Kebenaran komputasi diverifikasi dengan membandingkan posterior analitik konjugat, *Gibbs sampler* yang ditulis manual, dan HMC di Stan pada model dan prior yang sama.

3.6 Audit Reproducibility dan Skema Validasi

1. **Seed:** model final di-fit ulang dengan seed 777; bila ada parameter yang ditandai, dilanjutkan dengan audit lima seed (2026, 777, 999, 31, 123) untuk membandingkan sebaran antar-run dengan MCSE yang dilaporkan.
2. **Urutan data:** seed sama, baris data diacak.
3. **Skema validasi:** 5-fold per hull (4–5 hull utuh ditahan tiap fold) dibandingkan 5-fold acak per baris. Metrik pada satuan asli: RMSE, MAE, cakupan dan lebar interval prediksi 95%, serta ELPD per observasi.
4. **Sensitivitas prior:** semua SD prior M6 dikali 0.5 dan 2.5.

Kriteria stabil: selisih mean posterior |z| < 3 dalam satuan MCSE gabungan $z = \Delta / \sqrt{MCSE_1^2 + MCSE_2^2}$. Cross-validation memakai konfigurasi ringan (2 chains × 500 draws).

BAB 4. HASIL DAN PEMBAHASAN

4.1 Audit Kualitas Data

Table 4: Tabel 4.1 Ringkasan Audit Kualitas Data

Pemeriksaan	Hasil
Jumlah baris x kolom	308 x 7
Missing value	0
Duplikasi penuh	0
Hull form unik	22
Baris per hull	14
Level Froude number	14
Skewness target (mentah)	1.75
Skewness target log(1+y)	0.47
Shapiro-Wilk target (p-value)	4.85e-23
Outlier IQR pada target	42

Data lengkap tanpa duplikasi, dan desain eksperimennya **seimbang sempurna**: 22 hull × 14 Froude number = 308 baris. Temuan terpenting adalah struktur berkelompok ini: observasi dalam satu hull berbagi geometri yang sama, sehingga tidak saling independen. Outlier IQR pada target bukan kesalahan input, melainkan kondisi fisik valid pada kecepatan tinggi, sehingga **tidak dihapus**.

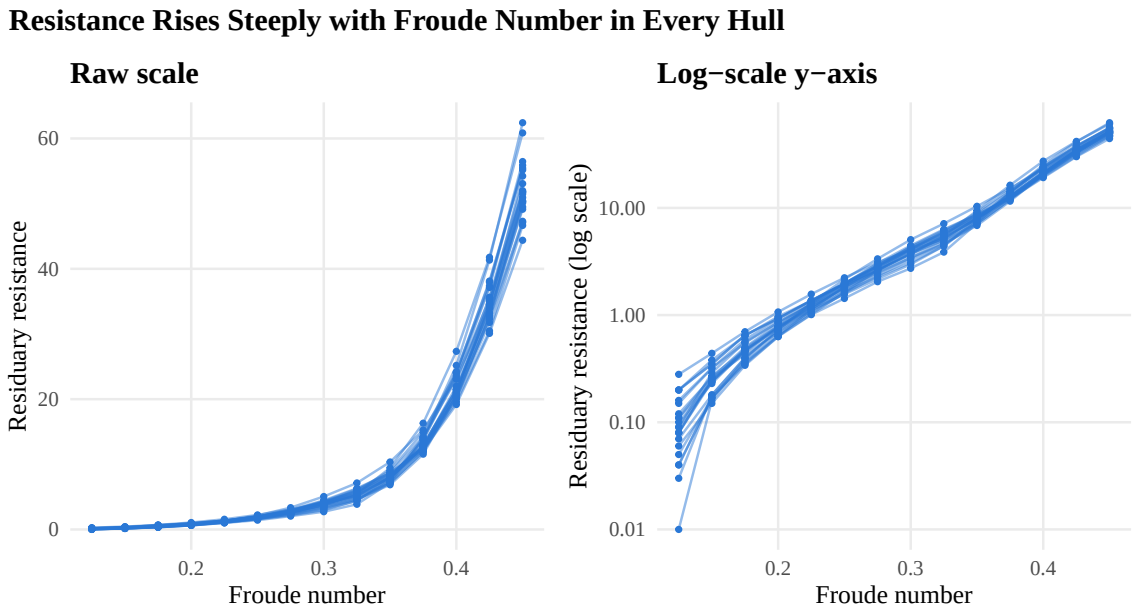


Figure 1: Gambar 4.1 Hubungan Froude Number dan Hambatan Residu per Hull (skala mentah dan log)

Setiap hull menunjukkan pola yang sama: datar pada Froude rendah lalu melonjak tajam setelah $Fr \approx 0.35$. Pola ini jauh lebih linear pada skala log. Distribusi target sangat miring ke kanan (skewness 1.75), sedangkan setelah transformasi $\log(1 + y)$ skewness menjadi 0.47. Temuan ini menjadi dasar Varian 2 (target log) dan Varian 3/spline (bentuk fungsi Froude).

4.2 Prior Predictive Check

Table 5: Tabel 4.2 Prior Predictive pada Satuan Asli Resistance

	share_negative	share_below_minus_0.5	share_gt_1000	q01	q50	q95	q99
M0 (Gaussian, raw)	0.366	0.360	0.000	-75.500	10.30	6.49e+01	9.71e+01
M6 (revised prior)	0.223	0.142	0.010	-0.974	4.21	1.91e+02	9.59e+02
M6 (initial wider prior)	0.393	0.350	0.197	-1.000	3.97	5.78e+07	6.15e+40
Observed data	0.000	0.000	0.000	0.041	3.06	4.99e+01	5.58e+01

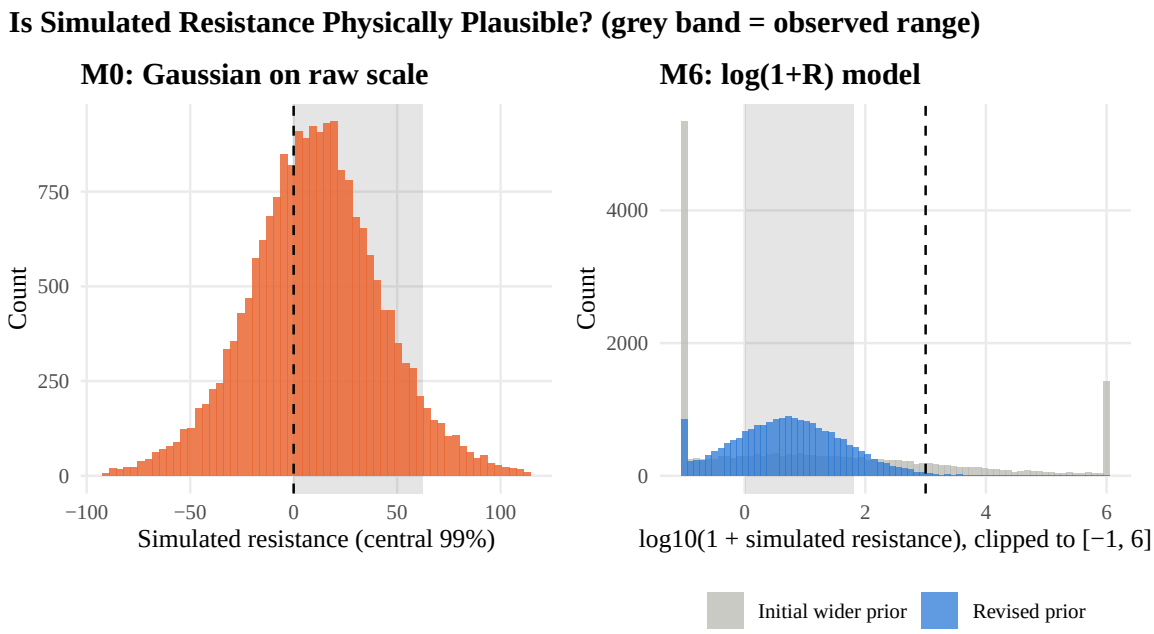


Figure 2: Gambar 4.2 Prior Predictive Check: M0 pada skala mentah dan M6 pada skala log

Prior predictive check memberi tiga temuan:

1. **M0** menghasilkan 37% resistance negatif. Penyebabnya bukan prior yang terlalu lebar, melainkan **likelihood Gaussian pada skala mentah yang tidak menghormati support** $y \geq 0$.
2. **Prior awal M6** tampak *weakly informative* pada skala terstandardisasi, tetapi setelah transformasi eksponensial menghasilkan resistance absurd (persentil-99 6.2e+40). Prior kemudian direvisi berdasarkan pemeriksaan ini.
3. **Prior revisi M6** menghasilkan orde besaran yang masuk akal (persentil-95 191, hanya 1.0% di atas 1000). Nilai sedikit negatif ($-1 < \mathrm{R} < 0$) masih muncul karena $\log(1 + y)$ mengizinkan $y > -1$; ini dicatat sebagai keterbatasan.

Koreksi versi awal (temuan audit). Versi awal analisis memasang prior $N(0, 1)$ langsung pada koefisien prediktor skala mentah. Prior itu menyatakan bahwa kenaikan Froude dari minimum ke maksimum hanya mengubah resistance sekitar ± 0.64, padahal data naik dari 0 ke 62. Hasilnya, koefisien Froude tertarik menjadi 1.69 dibanding OLS 121.67, **tanpa satu pun peringatan konvergensi**. Kasus ini menunjukkan mengapa standardisasi eksplisit dan prior predictive check wajib dilakukan.

4.3 Validasi Komputasi

Table 6: Tabel 4.3 OLS vs Posterior Analitik vs Gibbs Manual vs HMC (Stan), Prior NIG Identik

	OLS	Analytic_mean	Analytic_SD	Gibbs_mean	HMC_mean	HMC_MCSE	HMC_minus_Analytic_
Intercept	0.0000	0.0000	0.0336	0.0001	0.0000	0.0004	
z_LCB	0.0193	0.0192	0.0336	0.0193	0.0189	0.0004	
z_Prismatic_Coef	-0.0099	-0.0151	0.0596	-0.0147	-0.0162	0.0011	
z_LD_Ratio	0.0707	0.0492	0.1975	0.0497	0.0459	0.0037	
z_BD_Ratio	-0.0638	-0.0458	0.1670	-0.0458	-0.0430	0.0032	
z_LB_Ratio	-0.0739	-0.0528	0.1941	-0.0533	-0.0497	0.0037	
z_Froude_No	0.8101	0.8075	0.0336	0.8075	0.8077	0.0003	
sigma2	NA	0.3488	NA	0.3488	0.3485	NA	

Keempat pendekatan memberikan hasil praktis identik. Selisih terbesar HMC terhadap solusi analitik adalah 1.02 MCSE, konsisten dengan galat Monte Carlo. Log-likelihood yang ditulis manual (-1,115.9416) identik dengan log-likelihood Stan (-1,115.9416). Jadi komputasi benar; ketidakstabilan yang mungkin muncul bukan berasal dari sampler.

4.4 Baseline M0 dan Diagnosis Kegagalannya

Table 7: Tabel 4.4 Posterior Koefisien M0 dalam Satuan Asli (resistance per 1 unit prediktor)

	mean	sd	eti_2.5	eti_97.5	hdi_low	hdi_high	P_gt_0	OLS_raw_units
LCB	0.19	0.34	-0.47	0.87	-0.50	0.83	0.71	0.19
Prismatic_Coef	-9.65	37.35	-80.20	64.06	-82.12	61.18	0.40	-6.42
LD_Ratio	2.78	10.95	-18.23	24.58	-18.24	24.58	0.60	4.23
BD_Ratio	-1.21	4.27	-9.81	7.12	-10.11	6.79	0.39	-1.77
LB_Ratio	-3.06	11.03	-25.37	18.47	-26.15	17.59	0.39	-4.52
Froude_No	121.52	5.24	111.34	132.03	110.87	131.44	1.00	121.67

Slope Froude pada M0 = 121.5 dengan 95% *credible interval* [111.3, 132.0], dekat dengan OLS. Interpretasi Bayesian-nya: $P(\beta_{Fr} \in [\text{batas}] \mid y) = 0.95$, bersyarat pada model dan prior — berbeda dari *confidence interval* frequentist. Namun angka ini **belum layak diinterpretasikan** karena modelnya gagal pada model checking:

Table 8: Tabel 4.5 Discrepancy Statistics PPC Model M0

statistic	observed	rep_median	rep_2.5	rep_97.5	P_rep_ge_obs
mean	10.495	10.511	9.186	11.931	0.510
sd	15.160	15.216	13.828	16.496	0.534
max	62.420	49.087	42.218	58.040	0.004
skewness	1.748	-0.003	-0.197	0.196	0.000
share < 0	0.000	0.266	0.221	0.312	1.000

M0 mereplikasi *mean* dan *SD*, tetapi gagal pada aspek yang paling penting secara fisik: skewness dan maksimum tidak tereplikasi, sekitar 27% replikasi bernilai negatif, residual membentuk pola U terhadap Froude (**struktur mean salah**), dan sebarannya melebar pada Froude tinggi (**heteroskedastisitas**). Sesuai prinsip "ganti likelihood, bukan memaksa data", model diperbaiki secara bertahap (M1–M6).

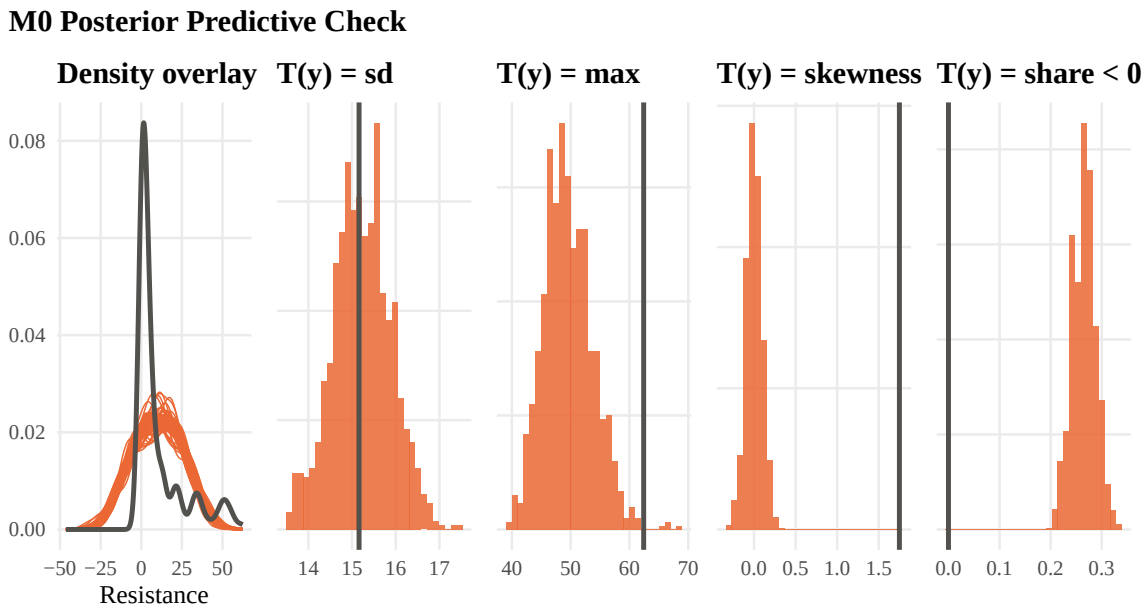


Figure 3: Gambar 4.3 Posterior Predictive Check Model M0 (garis gelap = statistik data teramati)

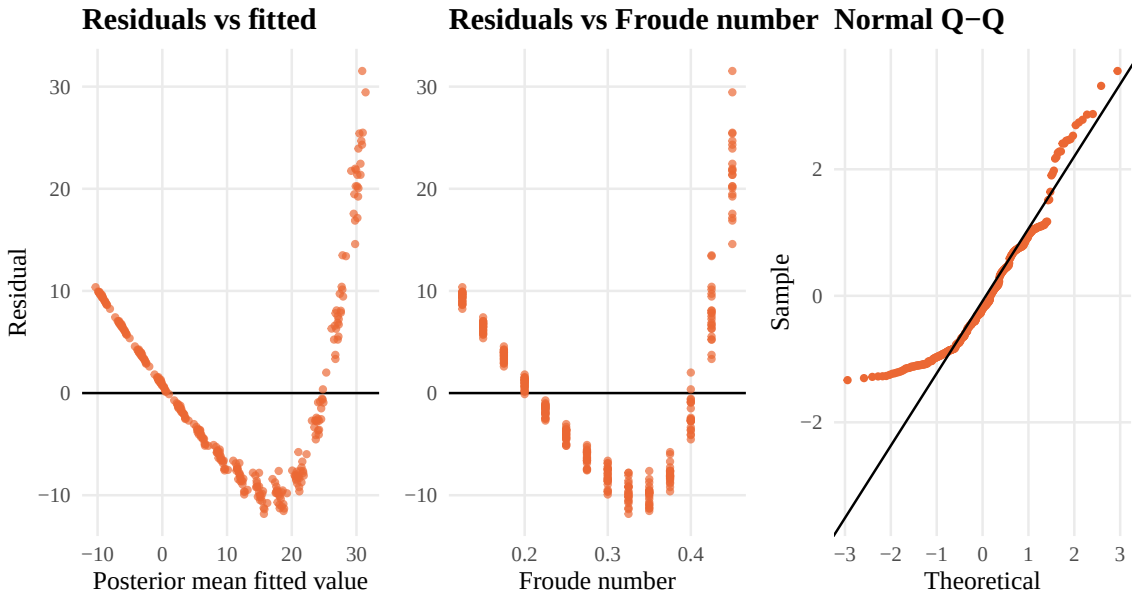


Figure 4: Gambar 4.4 Diagnostik Residual Model M0

4.5 Model Remedi dan Diagnostik Konvergensi

Table 9: Tabel 4.6 Diagnostik MCMC Seluruh Model (waktu sampling dalam detik)

model	sampling_s	max_rhat	min_ess_bulk	min_ess_tail	max_mcse_over_sd	divergences	verdict
M0	0.8	1.004	1175.753	1697.216	0.029	0	OK
M1	0.9	1.006	1204.603	1422.063	0.029	0	OK
M2	1.0	1.002	1092.401	1543.522	0.030	0	OK
M3	1.4	1.003	1315.544	1640.096	0.028	0	OK
M4	18.7	1.007	1400.677	2042.288	0.027	0	OK
M5	10.2	1.003	1389.435	1927.189	0.027	0	OK
M6	149.7	1.004	1036.491	1643.566	0.031	0	OK

Seluruh model memenuhi kriteria konvergensi (R 1.01, ESS 400, tanpa divergensi).

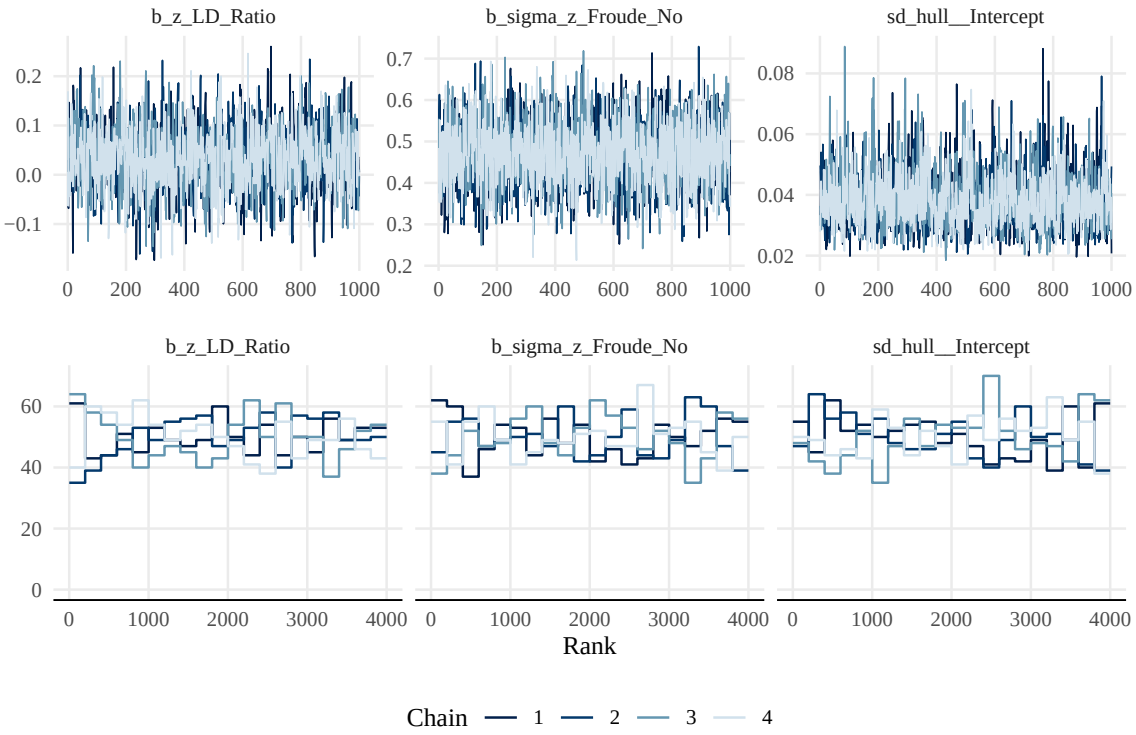


Figure 5: Gambar 4.5 Trace Plot dan Rank Plot Model M6

Table 10: Tabel 4.7 Variance Inflation Factor

	Kelompok	Prediktor	VIF
LCB	Geometri + Froude (M0, M1)	LCB	1.00
Prismatic_Coef	Geometri + Froude (M0, M1)	Prismatic_Coef	4.05
LD_Ratio	Geometri + Froude (M0, M1)	LD_Ratio	49.14
BD_Ratio	Geometri + Froude (M0, M1)	BD_Ratio	35.03
LB_Ratio	Geometri + Froude (M0, M1)	LB_Ratio	47.43
Froude_No	Geometri + Froude (M0, M1)	Froude_No	1.00

Froude	Suku polinomial Froude (M2)	Froude	6.48
Froude^2	Suku polinomial Froude (M2)	Froude^2	1.00
Froude^3	Suku polinomial Froude (M2)	Froude^3	6.48

Multikolinearitas terbesar terdapat pada rasio geometri LD, BD, dan LB (VIF 35–49). Hal ini wajar karena ketiganya dibentuk dari dimensi yang sama (panjang, lebar, sarat, volume). Prior $N(0, 0.5)$ bekerja sebagai regularisasi ridge yang menstabilkan estimasi, tetapi **tidak dapat menciptakan informasi** untuk memisahkan efek masing-masing rasio (Gambar 4.6).

4.6 Perbandingan Model: PSIS-LOO dan WAIC

Karena M0 memodelkan skala mentah sedangkan M1–M6 memodelkan $\log(1+y)$, log-likelihood setiap model dipindahkan ke satuan asli Resistance dengan koreksi Jacobian, yaitu $-\log s_y$ untuk M0 dan $-\log s_\ell - \log(1+y)$ untuk M1–M6. Tanpa koreksi ini perbandingan **tidak sah**.

Table 11: Tabel 4.8 Perbandingan Model dengan PSIS-LOO dan WAIC (satuan asli, koreksi Jacobian)

model	elpd_loo	se_elpd_loo	p_loo	elpd_diff	se_diff	elpd_waic	n_pareto_k_gt_0.7	diff_over_se
NULL	-122.31	32.51	28.53	0.00	0.00	NULL	NA	NA
NULL	-154.48	27.88	13.31	-32.17	9.95	NULL	NA	-3.23
NULL	-161.98	28.17	13.35	-39.67	11.15	NULL	NA	-3.56
NULL	-163.55	28.00	12.92	-41.25	11.27	NULL	NA	-3.66
NULL	-187.74	28.97	10.24	-65.44	13.57	NULL	NA	-4.82
NULL	-509.54	24.92	7.64	-387.23	17.10	NULL	NA	-22.64
NULL	-1117.33	14.83	8.77	-995.02	28.78	NULL	NA	-34.58

Perbaikan terbesar datang dari **preprocessing target dan bentuk fungsi Froude** (M0 → M1 → M2/M3), disusul pemodelan varians (M4) dan efek hull (M6). Namun perlu kehati-hatian: PSIS-LOO meninggalkan *satu baris*, sementara 13 baris lain dari hull yang sama tetap membantu mengestimasi efek hull tersebut. Keunggulan M6 di LOO karena itu harus diuji ulang dengan validasi per hull (Subbab 4.10).

4.7 Model Checking dan Posterior Model Final (M6)

Table 12: Tabel 4.9 Perbandingan Discrepancy Statistics M0 dan M6

Statistik	Observed	M0_rep_median	M0_P_rep_ge_obs	M6_rep_median	M6_rep_2.5	M6_rep_97.5	M6_P_rep_ge_o
mean	10.495	10.511	0.510	10.550	10.203	10.922	0.6
sd	15.160	15.216	0.534	15.416	14.552	16.338	0.7
max	62.420	49.087	0.004	68.371	58.736	82.847	0.8
skewness	1.748	-0.003	0.000	1.814	1.683	1.980	0.8
share < 0	0.000	0.266	1.000	0.003	0.000	0.010	1.0

Pada M6 seluruh statistik teramati berada di dalam distribusi replikasi. Sisa kecil adalah 0.3% replikasi bernilai sedikit negatif, akibat sifat transformasi $\log(1 + y)$.

Transformasi ke besaran yang bermakna dihitung langsung dari setiap draw posterior: +1 SD geometri mengubah $(1 + \text{Resistance})$ sebesar $100[\exp(\beta_j s_\ell) - 1]\%$.

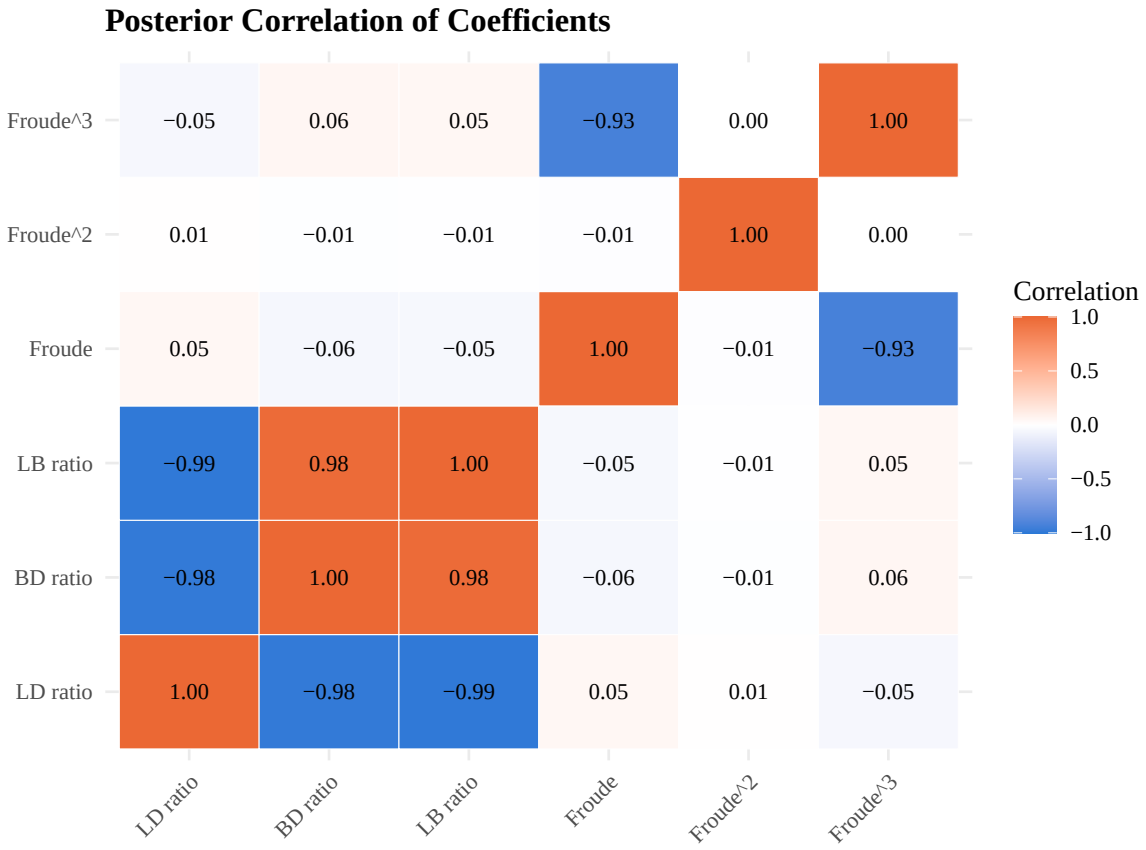


Figure 6: Gambar 4.6 Korelasi Posterior Antar-Koefisien (M2, Varian 3)

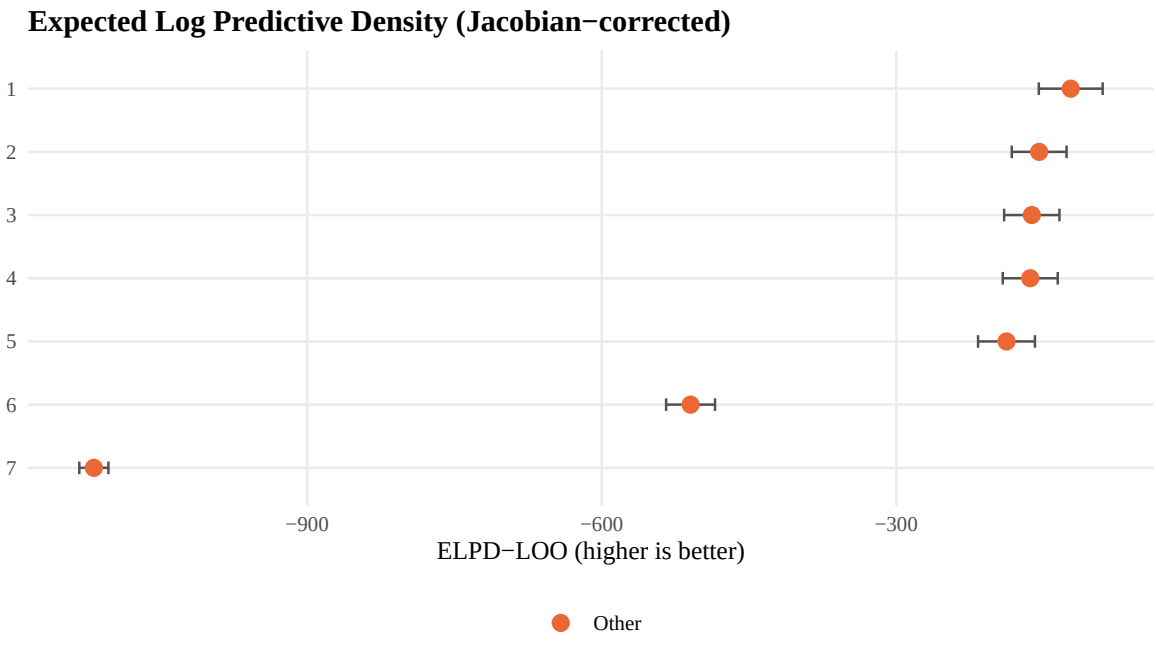


Figure 7: Gambar 4.7 ELPD-LOO Seluruh Model (plus-minus 1 SE)

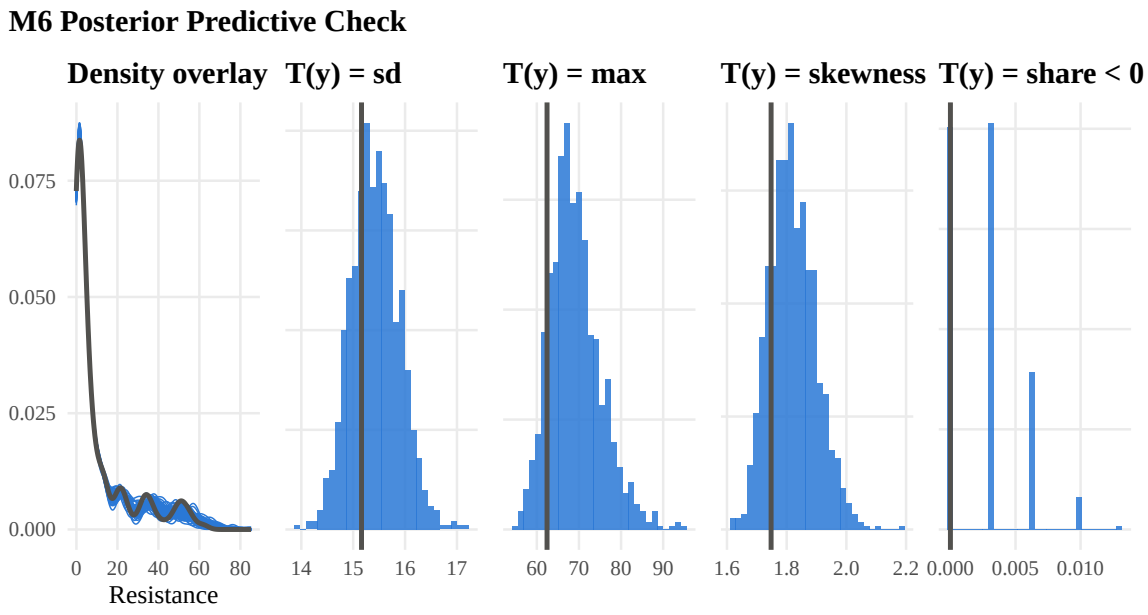


Figure 8: Gambar 4.8 Posterior Predictive Check Model M6

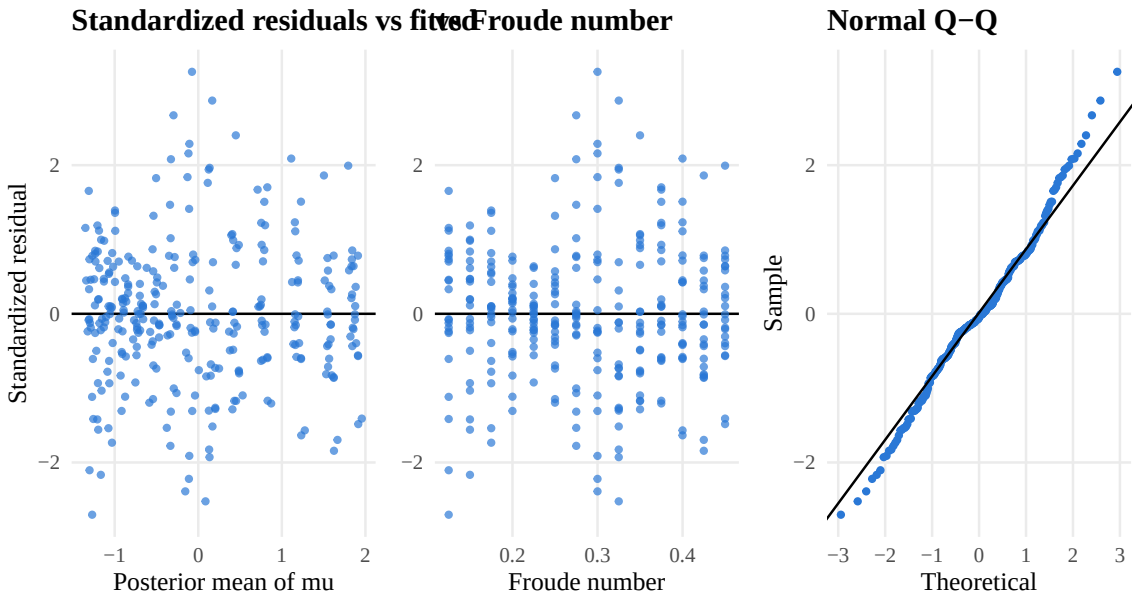


Figure 9: Gambar 4.9 Residual Terstandardisasi M6 (residual dibagi sigma yang dimodelkan)

Table 13: Tabel 4.10 Posterior Efek pada Model M6 (median, 95% ETI dan HDI, posterior probability)

	median	eti_2.5	eti_97.5	hdi_low	hdi_high	P_gt_0	P_abs_gt_1pct
LCB: % change per +1 SD	1.470	-0.719	3.536	-0.719	3.535	0.924	0.697
Prismatic_Coef: % change per +1 SD	0.103	-4.110	4.377	-4.179	4.240	0.524	0.617
LD_Ratio: % change per +1 SD	4.445	-10.530	20.728	-11.148	19.860	0.740	0.903
BD_Ratio: % change per +1 SD	-0.365	-11.969	13.123	-12.225	12.740	0.477	0.855
LB_Ratio: % change per +1 SD	-3.779	-16.688	11.946	-17.346	10.805	0.289	0.901
Residual SD multiplier per +1 SD Froude	1.598	1.388	1.848	1.370	1.828	1.000	1.000
Between-hull variation (%)	4.611	3.039	7.494	2.740	6.918	1.000	1.000

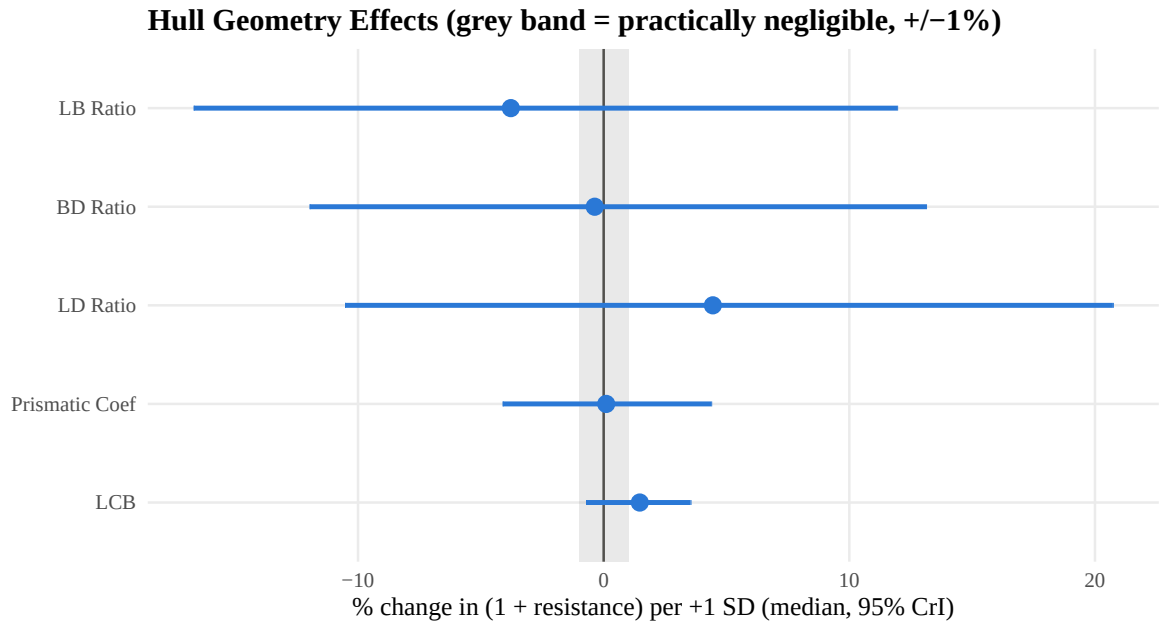


Figure 10: Gambar 4.10 Efek Geometri Lambung pada Model M6

Setelah bentuk fungsi Froude, varians, dan variasi antar-hull dimodelkan, efek per SD geometri hanya beberapa persen dan **arahnya tidak pasti**: $P(\text{efek} > 0 \mid y)$ berkisar 0.29–0.92. Sebaliknya, dua besaran diestimasi dengan sangat pasti. SD residual naik 1.60× per SD Froude (95% CrI 1.39–1.85; Gambar 4.11). Variasi antar-hull yang tidak dijelaskan geometri adalah 4.6% (3.0–7.5%).

4.8 Prediksi untuk Desain Lambung Baru

Skenario: lambung **baru** dengan geometri di median ke-22 desain, diuji pada 14 Froude number eksperimen (tanpa ekstrapolasi). Efek hull baru diambil dari distribusi populasi $u_{new} \sim N(0, \sigma^2_{hull})$.

Table 14: Tabel 4.11 Prediksi Lambung Baru: Median, Interval Prediksi 95%, dan Probabilitas Eksedans

Froude	pred_median	PI_2.5	PI_97.5	P_R_gt_5	P_R_gt_20
0.125	0.113	-0.008	0.255	0.000	0.000
0.150	0.265	0.121	0.430	0.000	0.000
0.175	0.488	0.313	0.698	0.000	0.000
0.200	0.809	0.585	1.066	0.000	0.000

0.225	1.243	0.949	1.586	0.000	0.000
0.250	1.851	1.455	2.290	0.000	0.000
0.275	2.682	2.152	3.315	0.000	0.000
0.300	3.829	3.068	4.717	0.005	0.000
0.325	5.484	4.436	6.773	0.803	0.000
0.350	8.169	6.478	10.231	1.000	0.000
0.375	12.992	10.233	16.320	1.000	0.000
0.400	21.866	16.913	28.100	1.000	0.764
0.425	35.852	27.247	47.752	1.000	1.000
0.450	51.852	37.699	69.270	1.000	1.000

Probabilitas eksedans seperti $P(R > 20 \mid y) = 0.76$ pada $Fr = 0.40$ dapat langsung dipakai untuk keputusan desain (misalnya kebutuhan daya propulsi). Band prediksi jauh lebih lebar daripada *credible band*: perbedaan antara **ketidakpastian estimasi** dan **ketidakpastian prediksi** adalah pesan utama dalam mengomunikasikan uncertainty.

4.9 Analisis Sensitivitas

Kompetisi Prior dan Data

Data dan likelihood dibuat tetap, hanya prior slope Froude yang diubah. Posterior konjugat dihitung untuk tiga ukuran data berbasis hull.

Table 15: Tabel 4.12 Kompetisi Prior-Data (prior pull = pangsa presisi prior dalam presisi posterior)

	data	prior	post_mean	post_sd	data_only_slope	prior_pull
z_Froude_No	1 hull (n=14)	Weak N(0, 1)	0.739	0.156	0.758	0.024
z_Froude_No1	1 hull (n=14)	Strong-correct N(0.81, 0.02)	0.809	0.020	0.758	0.984
z_Froude_No2	1 hull (n=14)	Strong-wrong N(0.40, 0.02)	0.406	0.020	0.758	0.984
z_Froude_No3	3 hulls (n=42)	Weak N(0, 1)	0.772	0.091	0.778	0.008
z_Froude_No11	3 hulls (n=42)	Strong-correct N(0.81, 0.02)	0.809	0.020	0.778	0.954
z_Froude_No21	3 hulls (n=42)	Strong-wrong N(0.40, 0.02)	0.417	0.020	0.778	0.954
z_Froude_No4	22 hulls (n=308)	Weak N(0, 1)	0.809	0.034	0.810	0.001
z_Froude_No12	22 hulls (n=308)	Strong-correct N(0.81, 0.02)	0.810	0.017	0.810	0.739
z_Froude_No22	22 hulls (n=308)	Strong-wrong N(0.40, 0.02)	0.507	0.017	0.810	0.739

Prior lemah praktis menghilang begitu ada 3 hull. Prior kuat yang **salah** dengan SD 0.02 tetap menarik posterior bahkan pada n = 308, karena SD prior itu lebih kecil daripada ketidakpastian yang diberikan data — prior ekstrem yang sangat terkonsentrasi dapat mendominasi lebih lama.

Sensitivitas Prior pada Model Final

Table 16: Tabel 4.13 Kesimpulan Prediktif di Bawah Tiga Skala Prior

prior	P_R20_Fr040	ELPD_LOO
Tighter (x0.5)	0.761	-123.082
Base (x1)	0.764	-122.307
Wider (x2.5)	0.763	-122.475

Mengubah semua SD prior dari $\times 0.5$ hingga $\times 2.5$ praktis tidak mengubah posterior maupun kesimpulan prediktif ($P(R > 20 \mid Fr = 0.40)$ berkisar 0.76–0.76). Untuk sensitivitas likelihood, posterior derajat bebas

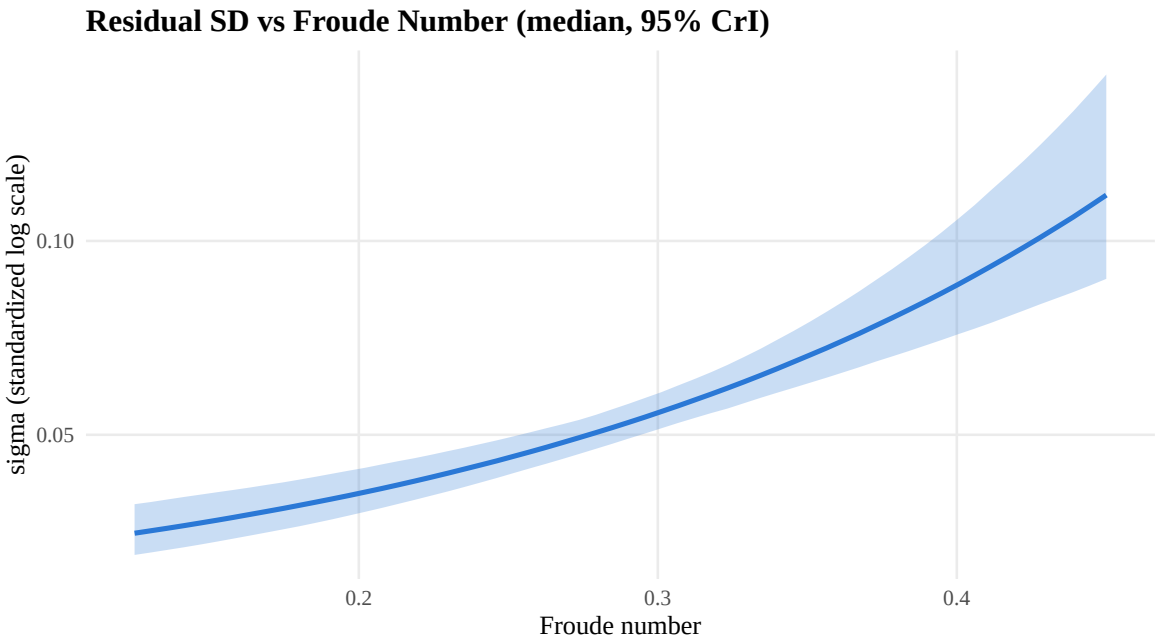


Figure 11: Gambar 4.11 Heteroskedastisitas yang Dimodelkan: SD Residual Meningkat dengan Froude Number

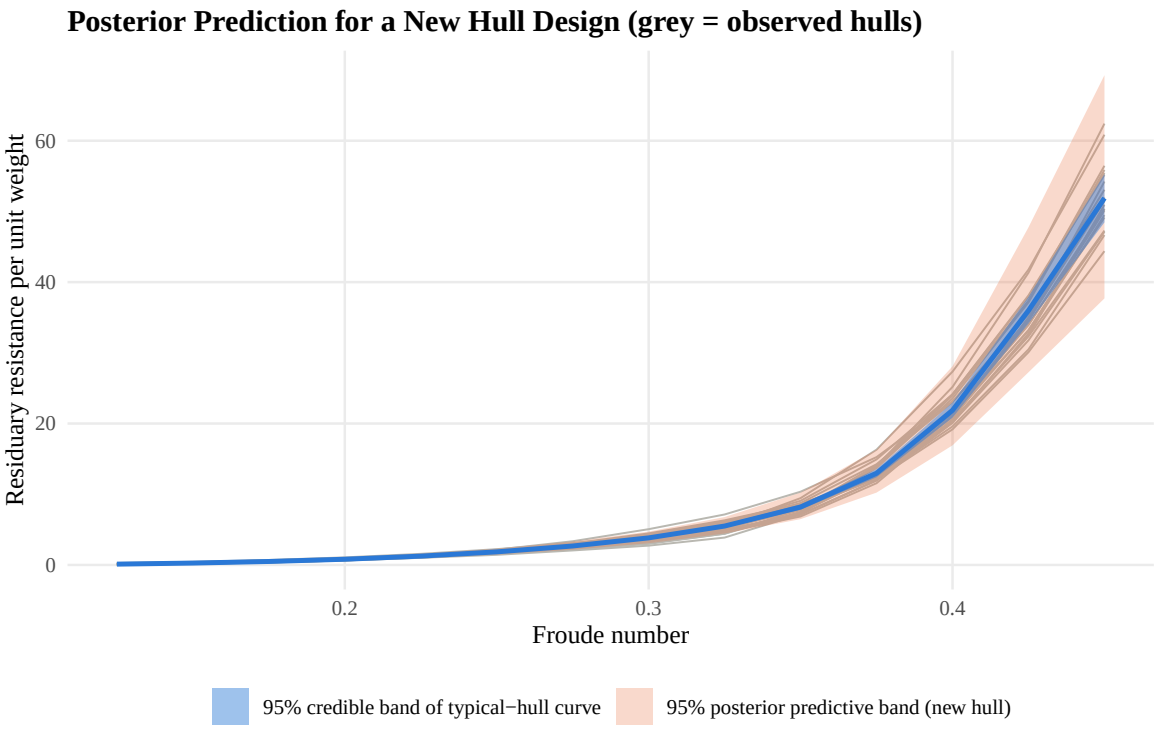


Figure 12: Gambar 4.12 Posterior Predictive untuk Lambung Baru: Credible Band vs Predictive Band

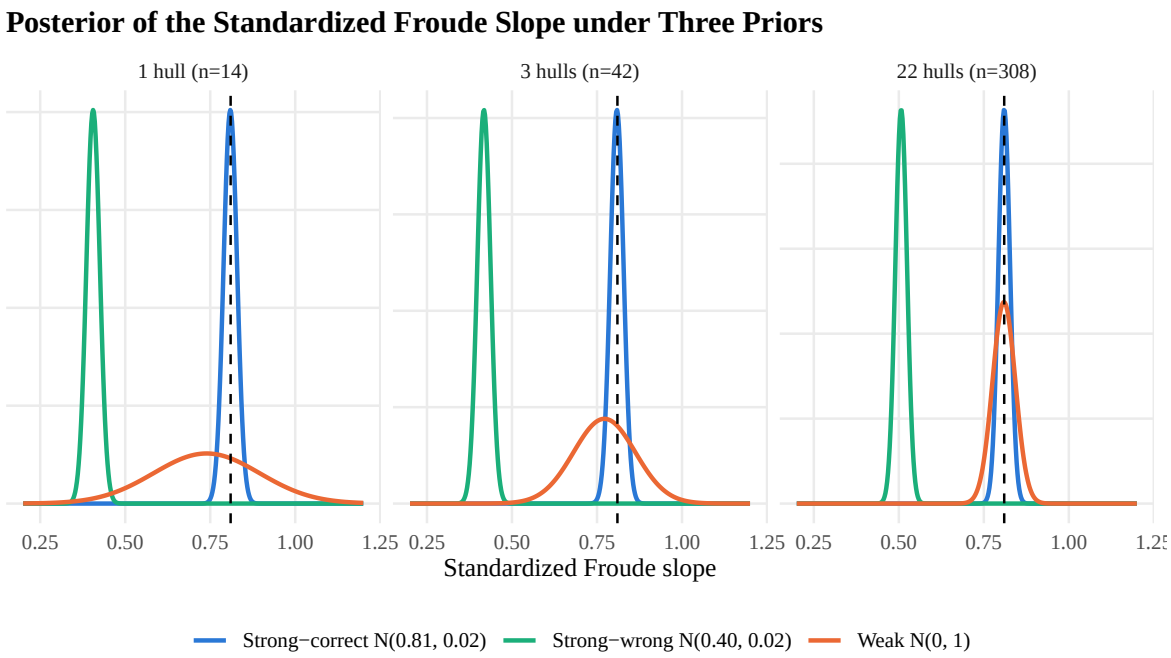


Figure 13: Gambar 4.13 Kompetisi Prior-Data pada Berbagai Ukuran Data

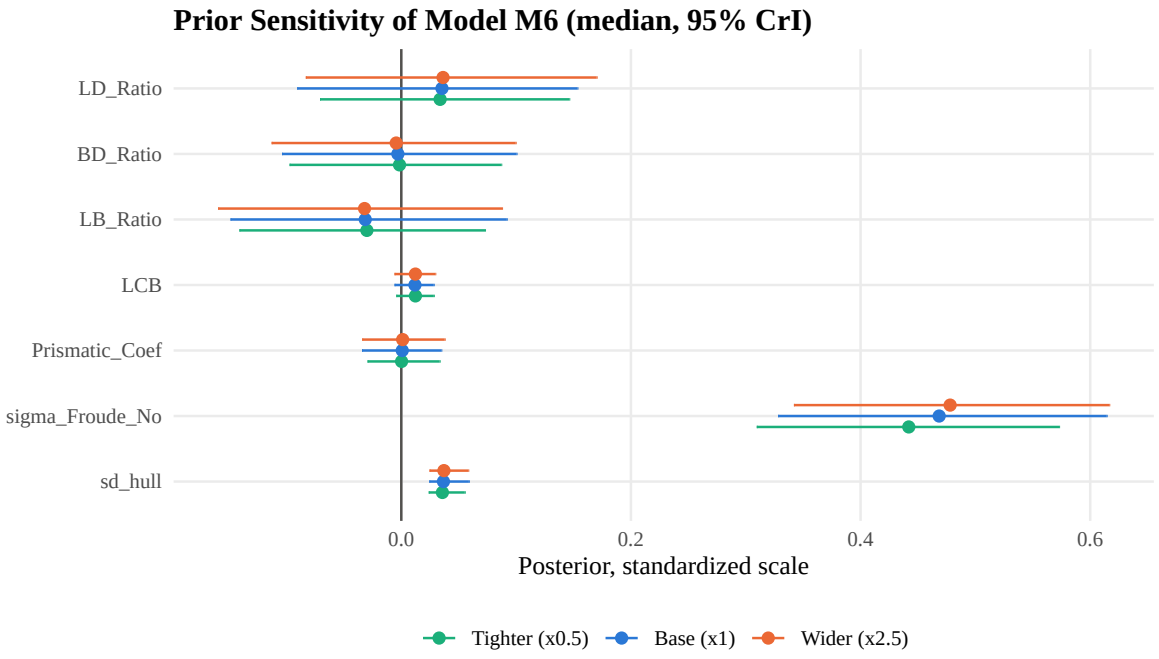


Figure 14: Gambar 4.14 Sensitivitas Posterior M6 terhadap Skala Prior

Student-t (M5) memiliki median 14.0, dan ELPD M5 − M3 = 1.57. Artinya, setelah transformasi log, ekor berat tidak diperlukan; perbaikan berasal dari struktur mean dan varians.

4.10 Audit Reproducibility

Seed dan Urutan Data

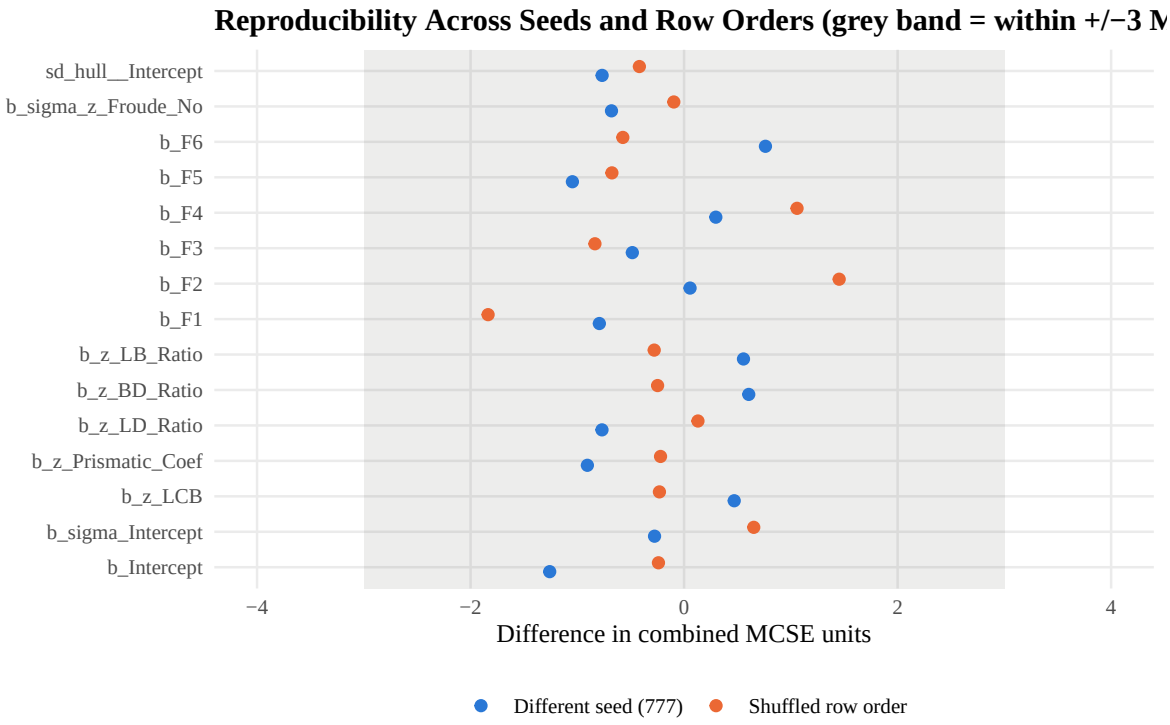


Figure 15: Gambar 4.15 Selisih Mean Posterior terhadap Run Referensi (satuan MCSE gabungan)

Selisih maksimum adalah 1.26 MCSE (seed) dan 1.84 MCSE (urutan data). Seluruh parameter memenuhi kriteria $|z| < 3$, sehingga perbedaan hanya berasal dari Monte Carlo error.

Table 17: Tabel 4.14 Audit Lima Seed: Sebaran Mean Posterior Antar-Run vs MCSE yang Dilaporkan

param	min_mean_5_seeds	max_mean_5_seeds	between_run_sd	mean_reported_mcse	ratio_sd_to_mcse
b_F1	0.08693	0.08769	0.00032	0.00022	1.42009
b_Intercept	-1.28009	-1.27956	0.00023	0.00020	1.14608
b_sigma_Intercept	-2.94556	-2.94405	0.00073	0.00072	1.01123
b_z_LCB	0.01185	0.01230	0.00018	0.00019	0.95647
b_z_Prismatic_Coef	-0.00012	0.00077	0.00039	0.00042	0.93260
b_z_BD_Ratio	-0.00307	-0.00030	0.00107	0.00126	0.84877
b_F5	2.93221	2.93335	0.00045	0.00053	0.83449
b_z_LB_Ratio	-0.03061	-0.02746	0.00122	0.00147	0.82661
b_z_LD_Ratio	0.03232	0.03525	0.00120	0.00149	0.80373
b_F6	3.14387	3.14448	0.00023	0.00036	0.63167
b_sigma_z_Froude_No	0.46702	0.46966	0.00095	0.00157	0.60436
b_F4	1.85962	1.86030	0.00027	0.00046	0.57985
sd_hull___Intercept	0.03760	0.03793	0.00014	0.00027	0.50606

b_F3	1.05966	1.06002	0.00014	0.00035	0.39325
b_F2	0.38851	0.38868	0.00007	0.00027	0.26574

Table 18: Tabel 4.15 Kesimpulan Substantif di Bawah Lima Seed

seed	between_hull_pct	P_R20_Fr040
2026	4.611	0.764
777	4.609	0.757
999	4.560	0.757
31	4.567	0.765
123	4.612	0.757

Rasio sebaran antar-run terhadap MCSE bernilai sekitar 1 untuk sebagian besar parameter (median 0.83). Untuk SD efek hull, rasionya 0.51: **MCSE meremehkan variabilitas nyata** parameter skala hierarkis, dan run referensi (seed 2026) kebetulan berada di sisi bawah. Secara substantif perbedaannya kecil: variasi antar-hull berkisar 4.56–4.61% dan $P(R > 20 \mid Fr = 0.40)$ berkisar 0.757–0.765 antar seed. Pelajarannya: untuk parameter skala hierarkis, satu run dan MCSE-nya belum cukup sebagai bukti reproducibility. Gunakan beberapa seed (atau lebih banyak draws), dan nilai stabilitas pada besaran yang menjadi dasar keputusan.

Validasi Per Hull vs Acak Per Baris dan Dampak Preprocessing

Table 19: Tabel 4.16 Hasil Cross-Validation 5-Fold (satuan asli Resistance)

model	scheme	RMSE	MAE	coverage_95	PI_width	ELPD_per_obs	ELPD_total	max_rhat_folds
M0	grouped	8.866	7.131	0.942	35.993	-3.603	-1109.732	1.022
M1	grouped	4.942	2.512	0.971	9.973	-1.640	-504.991	1.024
M2	grouped	2.137	0.953	0.942	3.852	-0.629	-193.783	1.020
M3	grouped	1.866	0.841	0.938	3.537	-0.567	-174.570	1.032
M4	grouped	2.014	0.901	0.919	4.286	-0.578	-177.927	1.013
M6	grouped	2.091	0.934	0.987	6.096	-0.628	-193.297	1.009
M4	row-random	1.870	0.848	0.938	4.188	-0.523	-160.971	1.011
M6	row-random	2.063	0.927	0.938	5.075	-0.422	-129.881	1.018

Table 20: Tabel 4.17 Perbandingan Berpasangan Leave-Hull-Out terhadap Model Terbaik (M3); SE per cluster hull

model	ELPD_total	elpd_diff	se_diff_obs	se_diff_hull	diff_over_se_hull
M3	-174.57	0.00	0.00	0.00	NA
M4	-177.93	-3.36	5.19	9.12	-0.37
M6	-193.30	-18.73	8.45	18.14	-1.03
M2	-193.78	-19.21	7.93	7.79	-2.47
M1	-504.99	-330.42	13.84	26.82	-12.32
M0	-1109.73	-935.16	24.64	27.31	-34.24

Table 21: Tabel 4.18 Optimisme Validasi Acak Per Baris dibanding Per Hull

model	ELPD_optimism	se	RMSE_grouped	RMSE_row	optimism_over_se
M4	16.96	4.74	2.01	1.87	3.58
M6	63.42	11.69	2.09	2.06	5.42

Temuan kunci audit validasi:

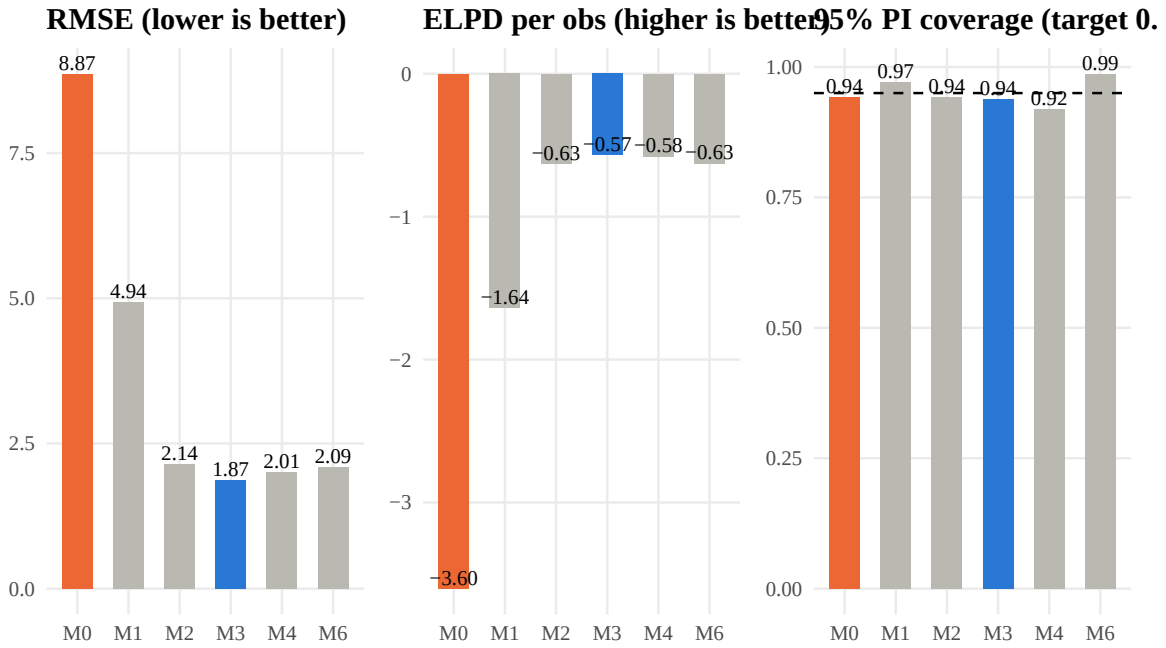


Figure 16: Gambar 4.16 Dampak Preprocessing dan Model pada Prediksi Hull Baru (leave-hull-out)

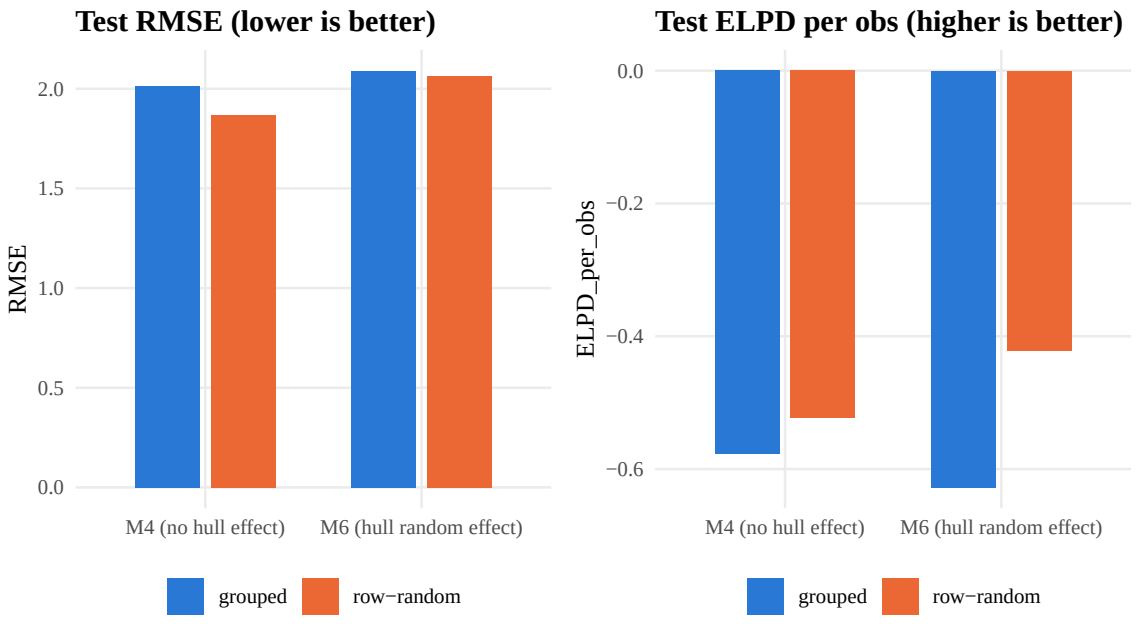


Figure 17: Gambar 4.17 Kebocoran Data: Validasi Acak Per Baris Terlalu Optimis untuk Hull Baru

1. **Preprocessing tidak stabil dan sangat menentukan.** RMSE per hull turun dari 8.87 (M0) ke 1.87 (M3); ELPD per observasi naik dari -3.60 ke -0.57. Cakupan M0 (0.94) tampak wajar hanya karena intervalnya sangat lebar (36.0) dan mencakup resistance negatif.
2. **Skema validasi mengubah model yang terpilih.** PSIS-LOO per baris memilih 1, sedangkan validasi per hull memilih M3. Selisih antar model berbasis spline (M3, M4, M6) untuk hull baru 1.0 SE (per cluster hull), sehingga ketiganya praktis setara.
3. **Kebocoran data terukur.** Validasi acak per baris melebih-lebihkan ELPD M6 sebesar 63.4 (SE 11.7), jauh lebih besar daripada M4 (17.0, SE 4.7), karena M6 "mengingat" efek tiap hull. Kebocoran terutama memengaruhi **lebar interval**, bukan titik prediksi.

Table 22: Tabel 4.19 Checklist Reproducibility (dievaluasi otomatis dari hasil run)

Item	Pass
Seed eksplisit tercatat	TRUE
Checksum SHA-256 data mentah tercatat	TRUE
Preprocessing scripted (make_frames)	TRUE
Standardisasi dihitung di dalam fold (tanpa kebocoran)	TRUE
Prior eksplisit + prior predictive check	TRUE
Komputasi divalidasi (analitik vs Gibbs vs HMC, < 3 MCSE)	TRUE
Likelihood manual = likelihood Stan	TRUE
Semua model: R-hat <= 1.01, ESS >= 400, 0 divergence	TRUE
Stabil terhadap seed (semua |z| < 3 MCSE)	TRUE
Stabil terhadap urutan data (semua |z| < 3 MCSE)	TRUE
Kesimpulan prediktif stabil antar 5 seed (rentang P(R>20 | Fr=0.40) < 0.05)	TRUE
Validasi per-hull dipakai untuk klaim prediktif	TRUE
Objek fit tersimpan (fits/*.rds)	TRUE

BAB 5. KESIMPULAN DAN SARAN

5.1 Kesimpulan

1. **Komputasi terverifikasi dan stabil secara substantif.** Posterior MCMC cocok dengan solusi analitik dan Gibbs (1.02 MCSE). Kesimpulan prediktif tidak berubah antar lima seed maupun urutan data, dan prior yang masih masuk akal tidak mengubah kesimpulan. Namun MCSE dari satu run meremehkan variabilitas antar-run untuk SD efek hull (0.5×), sehingga audit reproducibility perlu memakai beberapa seed.
2. **Keputusan kualitas data dan preprocessing mendominasi hasil.** Baseline Gaussian pada skala mentah konvergen sempurna tetapi salah spesifikasi. Transformasi log dan bentuk fungsi Froude yang fleksibel memperbaiki ELPD dan RMSE secara drastis. Prior yang salah skala mengubah kesimpulan tanpa peringatan konvergensi, sehingga prior predictive check wajib dilakukan.
3. **Skema validasi adalah sumber optimisme terbesar** dan bahkan mengubah model yang terpilih. Untuk estimand utama (prediksi lambung baru), validasi harus dilakukan per hull.
4. **Informatif untuk prediksi, terbatas untuk inferensi geometri.** Kurva resistance–Froude, heteroskedastisitas, dan variasi antar-hull diestimasi dengan presisi tinggi. Interval prediksi 95% M3 terkalibrasi baik untuk hull baru (cakupan 0.94), sedangkan M6 sedikit konservatif (0.99). Namun arah efek tiap rasio geometri tidak dapat dipastikan (22 hull, VIF tinggi).

5.2 Keterbatasan

1. Hanya 22 hull yang semuanya turunan satu *parent hull*; generalisasi ke keluarga desain lain tidak didukung.
2. Geometri divariasikan satu per satu di sekitar *parent hull*, sehingga efeknya lokal dan interaksi geometri tidak teridentifikasi.
3. Froude hanya 14 level (0.125–0.45); prediksi di luar rentang ini adalah ekstrapolasi.
4. Transformasi $\log(1 + y)$ masih mengizinkan nilai $-1 < \mathrm{y} < 0$.
5. Galat pengukuran *towing tank* tidak terdokumentasi.
6. Efek geometri adalah asosiasi dalam desain eksperimen ini, bukan klaim kausal umum.

5.3 Saran dan Pengembangan

1. Gunakan validasi per hull (atau per kelompok) untuk setiap klaim prediktif pada data berkelompok, dan laporkan optimisme skema acak sebagai bagian audit.
2. Uji likelihood yang hanya berlaku pada $y > 0$ (lognormal atau Gamma) untuk menghilangkan sisa pelanggaran support.
3. Untuk prediksi desain baru, gunakan model berbasis spline Froude yang lebih sederhana; gunakan M6 untuk menjelaskan struktur data.
4. Tambahkan data dari keluarga lambung lain agar efek geometri dapat diidentifikasi.

DAFTAR PUSTAKA

1. **Bürkner, P.-C. (2017).** brms: An R package for Bayesian multilevel models using Stan. *Journal of Statistical Software, 80*(1), 1–28. https://doi.org/10.18637/jss.v080.i01
2. **Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., & Rubin, D. B. (2013).** *Bayesian data analysis* (3rd ed.). CRC Press.
3. **Gelman, A., Vehtari, A., Simpson, D., Margossian, C. C., Carpenter, B., Yao, Y., Kennedy, L., Gabry, J., Bürkner, P.-C., & Modrák, M. (2020).** Bayesian workflow. *arXiv*. https://arxiv.org/abs/2011.01808
4. **Gerritsma, J., Onnink, R., & Versluis, A. (1981).** Geometry, resistance and stability of the Delft systematic yacht hull series. *International Shipbuilding Progress, 28*(328), 276–297.
5. **Hoff, P. D. (2009).** *A first course in Bayesian statistical methods*. Springer. https://doi.org/10.1007/978-0-387-92407-6
6. **Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., ... & Dormann, C. F. (2017).** Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography, 40*(8), 913–929. https://doi.org/10.1111/ecog.02881
7. **Vehtari, A., Gelman, A., & Gabry, J. (2017).** Practical Bayesian model evaluation using leave-one-out cross-validation and WAIC. *Statistics and Computing, 27*, 1413–1432. https://doi.org/10.1007/s11222-016-9696-4
8. **Vehtari, A., Gelman, A., Simpson, D., Carpenter, B., & Bürkner, P.-C. (2021).** Rank-normalization, folding, and localization: An improved $\widehat{R}$ for assessing convergence of MCMC. *Bayesian Analysis, 16*(2), 667–718. https://doi.org/10.1214/20-BA1221
9. **Gerritsma, J., Onnink, R., & Versluis, A. (1981).** *Yacht Hydrodynamics* [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5XG7R

ACKNOWLEDGEMENT

Sebagai wujud komitmen terhadap integritas akademik, kami menyatakan bahwa dalam penyelesaian project ini kami memanfaatkan *Artificial Intelligence*, yaitu Claude (Anthropic).

Penggunaan AI dibatasi sebagai alat pendukung (*assistive tool*): bantuan teknis dalam penulisan dan pemeriksaan kode R/Python, penyusunan struktur dan keterbacaan laporan, serta mitra diskusi dalam memvalidasi pemahaman terhadap *Bayesian workflow*. Pemeriksaan kode dengan bantuan AI juga menemukan kesalahan skala prior pada versi awal analisis (Subbab 4.2), yang kemudian diperbaiki dan didokumentasikan sebagai temuan audit.

Seluruh angka dalam laporan ini dihasilkan oleh kode yang dapat dijalankan ulang tanpa AI (`analisis_yacht_final.R`). Tidak ada angka yang diambil dari teks keluaran AI. Kami menegaskan bahwa verifikasi data, penalaran analitis, dan penarikan kesimpulan akhir dilakukan secara mandiri dan sepenuhnya menjadi tanggung jawab kami sebagai penulis.

LAMPIRAN

Lampiran A: Minimum Reporting Checklist (Bayesian Regression)

Table 23: Tabel A.1 Minimum Reporting Checklist

Item	Isi
Likelihood & link	Gaussian pada log(1+Resistance) terstandardisasi; geometri linear + B-spline Froude (df = 6) + efek acak hull;
Prior	Tabel 3.3 (divalidasi dengan prior predictive check, Subbab 4.2)
Software	R version 4.5.2 (2025-10-31 ucrt); brms 2.23.0; rstan 2.32.7; loo 2.10.1

Chains / iter / warm-up	4 / 2000 / 1000; adapt_delta 0.95; seed 2026
Diagnostik M6	max R-hat 1.004; min ESS bulk 1,036; min ESS tail 1,644; divergences 0
Posterior summary	Tabel 4.10: median, mean, mode, SD, 95% ETI & HDI, posterior probability
PPC	Gambar 4.3 & 4.8; Tabel 4.5 & 4.9
Sensitivitas	Subbab 4.9: prior x0.5/x1/x2.5; Gaussian vs Student-t; homo vs hetero; independen vs hierarkis
Perbandingan prediktif	PSIS-LOO & WAIC (Jacobian); leave-hull-out CV M6: RMSE 2.09, coverage 0.99

Lampiran B: Cara Mereproduksi

1. Letakkan `yacht_hydrodynamics.data`, `analisis_yacht_final.R`, dan file `.Rmd` ini dalam satu folder.
2. Pasang paket: `install.packages(c("brms", "rstan", "loo", "posterior", "dplyr", "tidyr", "kableExtra", "patchwork", "bayesplot", "digest", "jsonlite"))`.
3. *Knit* file `.Rmd`. Run pertama menghitung semua model (±40–60 menit); hasil disimpan di `fits/` dan `cache/` sehingga knit berikutnya jauh lebih cepat dan menghasilkan angka identik. Hapus kedua folder tersebut untuk menghitung ulang dari nol.
4. Checksum SHA-256 data mentah: 00dfecc0fc01ddd4c90b558a3ac11b246df8ebcfea130724223475a9a67f0ea1. Manifest lengkap tersimpan di `reproducibility_manifest_R.json`.

Lampiran C: Informasi Sesi R

```
R version 4.5.2 (2025-10-31 ucrt)
Platform: x86_64-w64-mingw32/x64
Running under: Windows 11 x64 (build 26200)

Matrix products: default
  LAPACK version 3.12.1

locale:
[1] LC_COLLATE=English_Indonesia.utf8  LC_CTYPE=English_Indonesia.utf8
[3] LC_MONETARY=English_Indonesia.utf8 LC_NUMERIC=C
[5] LC_TIME=English_Indonesia.utf8

time zone: Asia/Jakarta
tzcode source: internal

attached base packages:
[1] splines   stats     graphics  grDevices utils     datasets  methods
[8] base

other attached packages:
 [1] tidyr_1.3.1        dplyr_1.1.4        posterior_1.7.0    loo_2.10.1
 [5] rstan_2.32.7       StanHeaders_2.32.7 brms_2.23.0        Rcpp_1.1.0
 [9] bayesplot_1.16.0   patchwork_1.3.2    ggplot2_4.0.1      kableExtra_1.4.0
[13] knitr_1.50

loaded via a namespace (and not attached):
 [1] gtable_0.3.6         tensorA_0.36.2.1     QuickJSR_1.11.0
 [4] xfun_0.55            inline_0.3.21        lattice_0.22-7
 [7] vctrs_0.6.5          tools_4.5.2          generics_0.1.4
[10] stats4_4.5.2         parallel_4.5.2       sandwich_3.1-1
[13] tibble_3.3.0         pkgconfig_2.0.3      Matrix_1.7-4
[16] checkmate_2.3.4      RColorBrewer_1.1-3   S7_0.2.1
[19] distributional_0.9.0 RcppParallel_6.2.1   lifecycle_1.0.4
```

```
[22] compiler_4.5.2       farver_2.1.2         stringr_1.6.0
[25] textshaping_1.0.4    Brobdingnag_1.3-1    codetools_0.2-20
[28] htmltools_0.5.9      yaml_2.3.12          pillar_1.11.1
[31] MASS_7.3-65          bridgesampling_1.2-1 abind_1.4-8
[34] multcomp_1.4-29      nlme_3.1-168         tidyselect_1.2.1
[37] digest_0.6.39        mvtnorm_1.3-3        stringi_1.8.7
[40] reshape2_1.4.5       purrr_1.2.0          labeling_0.4.3
[43] fastmap_1.2.0        grid_4.5.2           cli_3.6.5
[46] magrittr_2.0.4       pkgbuild_1.4.8       survival_3.8-3
[49] TH.data_1.1-5        withr_3.0.2          scales_1.4.0
[52] backports_1.5.0      estimability_1.5.1   rmarkdown_2.30
[55] matrixStats_1.5.0    emmeans_2.0.2        gridExtra_2.3
[58] zoo_1.8-15           coda_0.19-4.1        evaluate_1.0.5
[61] viridisLite_0.4.2    rstantools_2.7.1     rlang_1.1.7
[64] xtable_1.8-4         glue_1.8.0           xml2_1.5.1
[67] jsonlite_2.0.0       svglite_2.2.2        rstudioapi_0.17.1
[70] plyr_1.8.9           R6_2.6.1             systemfonts_1.3.1
```

Lampiran D: Source Code Analisis Utama (R)

Berikut adalah kode R lengkap yang digunakan untuk seluruh analisis statistik dan pemodelan:

```
# ============================================================================
# analisis_yacht.R
# Regresi Bayesian + audit reproducibility & data quality - Yacht Hydrodynamics
# Seluruh pipeline dapat dijalankan ulang tanpa AI:  source("analisis_yacht.R")
# Hasil fit disimpan di folder fits/ dan cache/ agar knit ulang cepat & identik.
# ============================================================================

suppressPackageStartupMessages({
  library(brms)      # regresi Bayesian (Stan/HMC)
  library(rstan)     # model Stan konjugat untuk validasi komputasi
  library(loo)       # PSIS-LOO dan WAIC
  library(posterior) # ringkasan draws, R-hat, ESS, MCSE
  library(dplyr)
  library(tidyr)
  library(splines)
})

SEED <- 2026
set.seed(SEED)
N_CORES <- min(4, parallel::detectCores())
options(mc.cores = N_CORES)
rstan_options(auto_write = TRUE)
dir.create("fits", showWarnings = FALSE)
dir.create("cache", showWarnings = FALSE)

# Hasil mahal disimpan sebagai .rds; hapus folder cache/ dan fits/ untuk menghitung ulang dari nol
cache_rds <- function(name, expr) {
  f <- file.path("cache", paste0(name, ".rds"))
  if (file.exists(f)) return(readRDS(f))
  val <- expr
  saveRDS(val, f)
```

```
  val
}

SAMPLER    <- list(chains = 4, iter = 2000, warmup = 1000)   # 4 x 1000 draws
CV_SAMPLER <- list(chains = 2, iter = 1000, warmup = 500)    # konfigurasi ringan khusus CV
CONTROL    <- list(adapt_delta = 0.95)

# ------------------------------------------------------------------------------
# 1. DATA: load, nama kolom sesuai dokumentasi UCI 243, checksum
# ------------------------------------------------------------------------------
COLS <- c("LCB", "Prismatic_Coef", "LD_Ratio", "BD_Ratio", "LB_Ratio", "Froude_No", "Resistance")
PRED <- COLS[1:6]
GEOM <- COLS[1:5]
RAW_PATH <- "yacht_hydrodynamics.data"
df <- read.table(RAW_PATH, col.names = COLS)
RAW_SHA256 <- digest::digest(file = RAW_PATH, algo = "sha256")

geom_key <- do.call(paste, df[GEOM])
df$hull_id <- as.integer(factor(geom_key, levels = unique(geom_key)))

sdp  <- function(x) sqrt(mean((x - mean(x))^2))                  # SD populasi (ddof = 0)
skew <- function(x) mean((x - mean(x))^3) / sdp(x)^3

# ------------------------------------------------------------------------------
# 2. AUDIT KUALITAS DATA
# ------------------------------------------------------------------------------
rows_per_hull <- table(df$hull_id)
iqr_out <- sapply(COLS, function(v) {
  q <- quantile(df[[v]], c(.25, .75)); w <- diff(q)
  sum(df[[v]] < q[1] - 1.5 * w | df[[v]] > q[2] + 1.5 * w)
})
AUDIT <- list(
  n_rows = nrow(df), n_cols = length(COLS), n_missing = sum(is.na(df[COLS])),
  n_dup = sum(duplicated(df[COLS])), n_hull = length(unique(df$hull_id)),
  rows_per_hull = unique(as.integer(rows_per_hull)), n_froude = length(unique(df$Froude_No)),
  skew_raw = skew(df$Resistance), skew_log = skew(log1p(df$Resistance)),
  shapiro_p = shapiro.test(df$Resistance)$p.value, iqr_out = iqr_out,
  range = t(sapply(COLS, function(v) c(min = min(df[[v]]), max = max(df[[v]]),
                                       mean = mean(df[[v]]), sd = sd(df[[v]]))))
)

# ------------------------------------------------------------------------------
# 3. PREPROCESSING EKSPLISIT (statistik dihitung dari data TRAIN saja)
# ------------------------------------------------------------------------------
make_frames <- function(train, test = NULL) {
  sc <- lapply(PRED, function(v) c(mean(train[[v]]), sdp(train[[v]])))
  names(sc) <- PRED
  sc$y  <- c(mean(train$Resistance), sdp(train$Resistance))
  ly    <- log1p(train$Resistance)
  sc$ly <- c(mean(ly), sdp(ly))
  basis <- bs((train$Froude_No - sc$Froude_No[1]) / sc$Froude_No[2], df = 6)  # B-spline kubik, knot da
  tf <- function(d) {
    o <- as.data.frame(lapply(setNames(PRED, paste0("z_", PRED)),
                              function(v) (d[[v]] - sc[[v]][1]) / sc[[v]][2]))
```

```
    o$zF2 <- o$z_Froude_No^2
    o$zF3 <- o$z_Froude_No^3
    B <- predict(basis, o$z_Froude_No)
    colnames(B) <- paste0("F", 1:6)
    o <- cbind(o, as.data.frame(B))
    o$y_z  <- (d$Resistance - sc$y[1]) / sc$y[2]
    o$ly_z <- (log1p(d$Resistance) - sc$ly[1]) / sc$ly[2]
    o$hull <- sprintf("H%02d", d$hull_id)
    o$hull_id <- d$hull_id
    o$Froude_No <- d$Froude_No
    o$Resistance <- d$Resistance
    o
  }
  list(train = tf(train), test = if (!is.null(test)) tf(test), sc = sc, tf = tf)
}

full <- df[c(PRED, "Resistance", "hull_id")]
FR <- make_frames(full)
mdl <- FR$train
SCALE <- FR$sc

to_raw <- function(z, resp, sc) if (resp == "raw") z * sc$y[2] + sc$y[1] else expm1(z * sc$ly[2] + sc$ly
jacobian <- function(frame, resp, sc) {
  if (resp == "raw") rep(-log(sc$y[2]), nrow(frame)) else -log(sc$ly[2]) - log1p(frame$Resistance)
}

# ------------------------------------------------------------------------------
# 4. SPESIFIKASI MODEL & PRIOR
# ------------------------------------------------------------------------------
GEO <- paste0("z_", GEOM, collapse = " + ")
LIN <- paste(GEO, "+ z_Froude_No")
SPL <- paste0("F", 1:6, collapse = " + ")

SPECS <- list(
  M0 = list(label = "M0 Baseline: Gaussian, raw target (Variant 1)", f = paste("y_z ~", LIN),
            resp = "raw", fam = "gaussian", froude = "z_Froude_No", spline = FALSE, hetero = FALSE, hie
  M1 = list(label = "M1 Log target, linear (Variant 2)", f = paste("ly_z ~", LIN),
            resp = "log", fam = "gaussian", froude = "z_Froude_No", spline = FALSE, hetero = FALSE, hie
  M2 = list(label = "M2 Log target + Froude^2, ^3 (Variant 3)", f = paste("ly_z ~", LIN, "+ zF2 + zF3")
            resp = "log", fam = "gaussian", froude = c("z_Froude_No", "zF2", "zF3"), spline = FALSE, he
  M3 = list(label = "M3 Log target + Froude spline", f = paste("ly_z ~", GEO, "+", SPL),
            resp = "log", fam = "gaussian", froude = character(0), spline = TRUE, hetero = FALSE, hier =
  M4 = list(label = "M4 M3 + heteroskedastic sigma(Froude)", f = paste("ly_z ~", GEO, "+", SPL),
            resp = "log", fam = "gaussian", froude = character(0), spline = TRUE, hetero = TRUE, hier =
  M5 = list(label = "M5 M3 with Student-t likelihood", f = paste("ly_z ~", GEO, "+", SPL),
            resp = "log", fam = "student", froude = character(0), spline = TRUE, hetero = FALSE, hier =
  M6 = list(label = "M6 M4 + hull random intercept (final)", f = paste("ly_z ~", GEO, "+", SPL, "+ (1 |
            resp = "log", fam = "gaussian", froude = character(0), spline = TRUE, hetero = TRUE, hier =
)

make_formula <- function(sp) {
  if (sp$hetero) bf(as.formula(sp$f), sigma ~ z_Froude_No) else bf(as.formula(sp$f))
}
```

```
# s = pengali skala SD prior (1 = dasar, 0.5 lebih ketat, 2.5 lebih lebar) untuk analisis sensitivitas
make_prior <- function(sp, s = 1) {
  p <- prior_string(sprintf("normal(0, %g)", 1 * s), class = "Intercept") +
       prior_string(sprintf("normal(0, %g)", 0.5 * s), class = "b")                  # geometri
  for (v in sp$froude) p <- p + prior_string(sprintf("normal(0, %g)", 1 * s), class = "b", coef = v)
  if (sp$spline) for (k in 1:6) p <- p + prior_string(sprintf("normal(0, %g)", 1.5 * s), class = "b", c
  if (sp$hetero) {
    p <- p + prior_string(sprintf("normal(-1.5, %g)", 0.75 * s), class = "Intercept", dpar = "sigma") +
             prior_string(sprintf("normal(0, %g)", 0.5 * s), class = "b", dpar = "sigma")
  } else {
    p <- p + prior_string(sprintf("exponential(%g)", 1 / s), class = "sigma")          # rate = 1/s
  }
  if (sp$fam == "student") p <- p + prior(gamma(2, 0.1), class = "nu")               # shape-rate
  if (sp$hier) p <- p + prior_string(sprintf("normal(0, %g)", 0.25 * s), class = "sd")  # half-normal
  p
}

fit_model <- function(name, data = mdl, s = 1, seed = SEED, tag = name, sampler = SAMPLER) {
  sp <- SPECS[[name]]
  invisible(gc())                                       # bebaskan memori sebelum kompilasi Stan
  brm(make_formula(sp), data = data,
      family = if (sp$fam == "student") student() else gaussian(),
      prior = make_prior(sp, s), chains = sampler$chains, iter = sampler$iter,
      warmup = sampler$warmup, cores = N_CORES, seed = seed, control = CONTROL,
      refresh = 0, silent = 2, file = file.path("fits", tag), file_refit = "on_change")
}

MAIN_PAR <- function(fit) grep("^b_|^sigma$|^sd_|^nu$", variables(fit), value = TRUE)

diag_row <- function(fit, name) {
  t0 <- sum(rstan::get_elapsed_time(fit$fit))
  s <- summarise_draws(as_draws_array(fit, variable = MAIN_PAR(fit)),
                       "mean", "sd", "rhat", "ess_bulk", "ess_tail", "mcse_mean")
  np <- nuts_params(fit)
  data.frame(model = name, sampling_s = round(t0, 1), max_rhat = max(s$rhat),
             min_ess_bulk = min(s$ess_bulk), min_ess_tail = min(s$ess_tail),
             max_mcse_over_sd = max(s$mcse_mean / s$sd),
             divergences = sum(np$Value[np$Parameter == "divergent__"]))
}

loo_raw <- function(fit, name, data = mdl) {
  ll <- log_lik(fit)
  ll <- sweep(ll, 2, jacobian(data, SPECS[[name]]$resp, SCALE), "+")   # pindah ke satuan asli Resistan
  chain_id <- rep(seq_len(nchains(fit)), each = ndraws(fit) / nchains(fit))
  list(loo = loo(ll, r_eff = relative_eff(exp(ll), chain_id = chain_id)), waic = waic(ll))
}

# ---------------------------------------------------------------------------
# 5. PRIOR PREDICTIVE CHECK (simulasi eksplisit dari prior, materi Bag. 5.3)
# ---------------------------------------------------------------------------
prior_predictive <- function(name, S = 1000, wide = FALSE) {
  sp <- SPECS[[name]]
  set.seed(SEED)
  Xg <- scale(as.matrix(mdl[paste0("z_", GEOM)]), scale = FALSE)          # brms: intercept pada predik
```

```
  zF <- mdl$z_Froude_No
  out <- matrix(NA_real_, S, nrow(mdl))
  for (s in 1:S) {
    ic  <- rnorm(1, 0, if (wide) 2.5 else 1)
    mu  <- ic + Xg %*% rnorm(length(GEOM), 0, if (wide) 1 else 0.5)
    if (sp$spline) {
      Fm <- scale(as.matrix(mdl[paste0("F", 1:6)]), scale = FALSE)
      mu <- mu + Fm %*% rnorm(6, 0, if (wide) 2.5 else 1.5)
    } else {
      mu <- mu + (zF - mean(zF)) * rnorm(1, 0, 1)
    }
    if (sp$hier) {
      u <- rnorm(AUDIT$n_hull, 0, abs(rnorm(1, 0, if (wide) 1 else 0.25)))
      mu <- mu + u[mdl$hull_id]
    }
    sig <- if (sp$hetero) exp(rnorm(1, if (wide) 0 else -1.5, if (wide) 2 else 0.75) +
                              rnorm(1, 0, if (wide) 1 else 0.5) * zF) else rexp(1, 1)
    out[s, ] <- rnorm(nrow(mdl), mu, sig)
  }
  to_raw(out, sp$resp, SCALE)
}
PRIOR_PRED <- cache_rds("prior_predictive", list(
  M0 = prior_predictive("M0"), M6 = prior_predictive("M6"), M6_initial = prior_predictive("M6", wide = 

pp_summary <- function(v) {
  v <- v[is.finite(v)]
  c(share_negative = mean(v < 0), share_below_minus_0.5 = mean(v < -0.5), share_gt_1000 = mean(v > 1000)
    q01 = unname(quantile(v, .01)), q50 = median(v), q95 = unname(quantile(v, .95)), q99 = unname(quanti
}

# ------------------------------------------------------------------------------
# 6. PRIOR SALAH SKALA (reproduksi kesalahan versi awal, materi Bag. 7/10A)
# ------------------------------------------------------------------------------
fit_old <- brm(as.formula(paste("Resistance ~", paste(PRED, collapse = " + "))), data = df,
               prior = prior_string(sprintf("normal(%g, %g)", mean(df$Resistance), 2.5 * sd(df$Resistanc
                       prior(normal(0, 1), class = "b") +
                       prior_string(sprintf("normal(0, %g)", sd(df$Resistance)), class = "sigma"),
               chains = CV_SAMPLER$chains, iter = CV_SAMPLER$iter, warmup = CV_SAMPLER$warmup, cores = 
               seed = SEED, refresh = 0, silent = 2, file = "fits/old_misscaled_prior", file_refit = "or
Xraw <- cbind(1, as.matrix(df[PRED]))
b_ols_raw <- drop(solve(crossprod(Xraw), crossprod(Xraw, df$Resistance)))
OLD <- list(ols = b_ols_raw[["Froude_No"]], old = fixef(fit_old)["Froude_No", ],
            prior_span95 = 1.96 * diff(range(df$Froude_No)))

# ------------------------------------------------------------------------------
# 7. VALIDASI KOMPUTASI: analitik konjugat vs Gibbs manual vs HMC (Stan)
# ------------------------------------------------------------------------------
X <- cbind(Intercept = 1, as.matrix(mdl[paste0("z_", PRED)]))
y <- mdl$y_z
n <- nrow(X); p <- ncol(X)
m0 <- rep(0, p); V0 <- diag(p); a0 <- 2; b0 <- 1
V0i <- solve(V0)
Vn <- solve(V0i + crossprod(X))
mn <- drop(Vn %*% (V0i %*% m0 + crossprod(X, y)))
```

```
an <- a0 + n / 2
bn <- b0 + 0.5 * drop(crossprod(y) + t(m0) %*% V0i %*% m0 - t(mn) %*% solve(Vn) %*% mn)
sd_analytic <- sqrt(diag(Vn) * bn / (an - 1))
b_ols <- drop(solve(crossprod(X), crossprod(X, y)))

GIBBS <- cache_rds("gibbs", {
  set.seed(SEED)
  B <- 12000; burn <- 2000
  beta <- matrix(0, B, p); s2 <- rep(1, B)
  L <- t(chol(Vn))
  for (it in 2:B) {
    beta[it, ] <- mn + sqrt(s2[it - 1]) * drop(L %*% rnorm(p))
    r <- y - X %*% beta[it, ]
    dp <- beta[it, ] - m0
    s2[it] <- 1 / rgamma(1, shape = a0 + (n + p) / 2,
                         rate = b0 + 0.5 * drop(crossprod(r) + t(dp) %*% V0i %*% dp))  # 1/sigma2 ~ Gamm
  }
  list(beta = beta[-(1:burn), ], s2 = s2[-(1:burn)])
})

NIG_STAN <- "
data { int<lower=1> N; int<lower=1> P; matrix[N, P] X; vector[N] y; real a0; real b0; }
parameters { real<lower=0> sigma2; vector[P] beta_raw; }
transformed parameters { vector[P] beta = sqrt(sigma2) * beta_raw; }
model { sigma2 ~ inv_gamma(a0, b0); beta_raw ~ std_normal(); y ~ normal(X * beta, sqrt(sigma2)); }
"
HMC_NIG <- cache_rds("hmc_nig", {
  sm <- stan_model(model_code = NIG_STAN)
  fit <- sampling(sm, data = list(N = n, P = p, X = X, y = y, a0 = a0, b0 = b0),
                  chains = 4, iter = 3000, warmup = 1000, seed = SEED, refresh = 0)
  summarise_draws(as_draws_array(fit), "mean", "sd", "mcse_mean", "rhat", "ess_bulk")
})
hmc_beta <- HMC_NIG[grepl("^beta\\[", HMC_NIG$variable), ]
COMP <- data.frame(
  OLS = b_ols, Analytic_mean = mn, Analytic_SD = sd_analytic, Gibbs_mean = colMeans(GIBBS$beta),
  HMC_mean = hmc_beta$mean, HMC_MCSE = hmc_beta$mcse_mean, row.names = colnames(X))
COMP$HMC_minus_Analytic_in_MCSE <- (COMP$HMC_mean - COMP$Analytic_mean) / COMP$HMC_MCSE
SIGMA2 <- c(Analytic = bn / (an - 1), Gibbs = mean(GIBBS$s2),
            HMC = HMC_NIG$mean[HMC_NIG$variable == "sigma2"])

# log-likelihood manual (materi Bag. 4) untuk diverifikasi terhadap Stan
loglik_gaussian <- function(beta, sigma, X, y) sum(dnorm(y, drop(X %*% beta), sigma, log = TRUE))

# ------------------------------------------------------------------------------
# 8. FIT MODEL M0 - M6
# ------------------------------------------------------------------------------
FITS <- lapply(setNames(names(SPECS), names(SPECS)), fit_model)
DIAG <- bind_rows(lapply(names(FITS), function(m) diag_row(FITS[[m]], m)))
DIAG$verdict <- ifelse(DIAG$max_rhat <= 1.01 & DIAG$min_ess_bulk >= 400 & DIAG$min_ess_tail >= 400 &
                         DIAG$divergences == 0, "OK", "CHECK")

# verifikasi likelihood manual pada satu posterior draw M0
d0 <- as_draws_df(FITS$M0)
LL_CHECK <- c(
```

```
  manual = loglik_gaussian(unlist(d0[1, paste0("b_", c("Intercept", paste0("z_", PRED)))]), d0$sigma[1]
    n * (-log(SCALE$y[2])),
  stan = sum(log_lik(FITS$M0, draw_ids = 1)) + n * (-log(SCALE$y[2])))

# ------------------------------------------------------------------------------
# 9. LOO / WAIC (koreksi Jacobian ke satuan asli Resistance)
# ------------------------------------------------------------------------------
# Kompatibilitas cache loo:
# Object loo yang tersimpan dari versi package lama dapat memiliki struktur
# diagnostik Pareto-k yang berbeda. Ambil Pareto-k dari struktur yang tersedia,
# dan bila cache lama tidak menyimpannya, hitung ulang LOOS dari fit saat ini.
extract_pareto_k <- function(x) {
  if (is.null(x)) return(NULL)

  # Struktur utama pada loo modern
  if (!is.null(x$diagnostics) && !is.null(x$diagnostics$pareto_k)) {
    return(as.numeric(x$diagnostics$pareto_k))
  }

  # Fallback yang tetap tersedia pada objek loo dengan pointwise diagnostics
  if (!is.null(x$pointwise) &&
      "influence_pareto_k" %in% colnames(x$pointwise)) {
    return(as.numeric(x$pointwise[, "influence_pareto_k"]))
  }

  # Fallback terakhir bila psis object tersimpan
  if (!is.null(x$psis_object)) {
    out <- tryCatch(loo::pareto_k_values(x$psis_object),
                    error = function(e) NULL)
    if (!is.null(out)) return(as.numeric(out))
  }

  NULL
}

build_loos <- function() {
  lapply(setNames(names(FITS), names(FITS)),
         function(m) loo_raw(FITS[[m]], m))
}

LOOS <- cache_rds("loos", build_loos())

# Cache loo lama mungkin sah untuk ELPD/WAIC tetapi tidak menyimpan
# diagnostik Pareto-k yang dikenali oleh versi loo yang sedang dipakai.
# Dalam kondisi ini, cache khusus LOO dibangun ulang dari posterior yang ada.
has_pareto_k <- vapply(LOOS, function(z) {
  pk <- extract_pareto_k(z$loo)
  length(pk) > 0 && any(is.finite(pk))
}, logical(1))

if (!all(has_pareto_k)) {
  unlink(file.path("cache", "loos.rds"))
  LOOS <- cache_rds("loos", build_loos())
}
```

```
loo_cmp <- loo_compare(lapply(LOOS, `[[`, "loo"))
LOO_TAB <- data.frame(model = rownames(loo_cmp), loo_cmp[, c("elpd_loo", "se_elpd_loo", "p_loo", "elpd_
                      row.names = NULL)
LOO_TAB$elpd_waic <- sapply(LOO_TAB$model, function(m) LOOS[[m]]$waic$estimates["elpd_waic", "Estimate"]

LOO_TAB$n_pareto_k_gt_0.7 <- sapply(LOO_TAB$model, function(m) {
  pk <- extract_pareto_k(LOOS[[m]]$loo)
  if (is.null(pk)) return(NA_integer_)
  sum(pk > 0.7, na.rm = TRUE)
})

LOO_TAB$diff_over_se <- ifelse(LOO_TAB$se_diff > 0, LOO_TAB$elpd_diff / LOO_TAB$se_diff, NA)

# ------------------------------------------------------------------------------
# 10. PPC & RESIDUAL (satuan asli)
# ------------------------------------------------------------------------------
ppc_raw <- function(name, ndraws = 1000) {
  set.seed(SEED)
  to_raw(posterior_predict(FITS[[name]], ndraws = ndraws), SPECS[[name]]$resp, SCALE)
}
STATS <- list(mean = mean, sd = sd, max = max, skewness = skew, `share < 0` = function(v) mean(v < 0))
ppc_table <- function(yrep, yobs) {
  do.call(rbind, lapply(names(STATS), function(k) {
    rep <- apply(yrep, 1, STATS[[k]]); obs <- STATS[[k]](yobs)
    data.frame(statistic = k, observed = obs, rep_median = median(rep), rep_2.5 = unname(quantile(rep,
               rep_97.5 = unname(quantile(rep, .975)), P_rep_ge_obs = mean(rep >= obs))
  }))
}
YOBS <- mdl$Resistance
YREP <- cache_rds("yrep", list(M0 = ppc_raw("M0"), M6 = ppc_raw("M6")))
PPC <- list(M0 = ppc_table(YREP$M0, YOBS), M6 = ppc_table(YREP$M6, YOBS))

MU_M0 <- colMeans(to_raw(posterior_linpred(FITS$M0), "raw", SCALE))
MU6 <- colMeans(posterior_linpred(FITS$M6))
SIG6 <- colMeans(posterior_linpred(FITS$M6, dpar = "sigma", transform = TRUE))
RES6 <- (mdl$ly_z - MU6) / SIG6

# VIF dan korelasi posterior (materi Bag. 16, 24.4)
vif_table <- function(M) sapply(seq_len(ncol(M)), function(i) 1 / (1 - summary(lm(M[, i] ~ M[, -i]))$r.s
VIF <- list(geometry = setNames(vif_table(as.matrix(mdl[paste0("z_", PRED)])), PRED),
            poly = setNames(vif_table(as.matrix(mdl[c("z_Froude_No", "zF2", "zF3")])), c("Froude", "Frou
POST_COR <- cor(as.data.frame(as_draws_df(FITS$M2))[, paste0("b_", c("z_LD_Ratio", "z_BD_Ratio", "z_LB_

# ------------------------------------------------------------------------------
# 11. POSTERIOR MANAGEMENT
# ------------------------------------------------------------------------------
hdi <- function(v, prob = .95) {
  v <- sort(v); k <- floor(prob * length(v)); w <- v[(k + 1):length(v)] - v[1:(length(v) - k)]
  i <- which.min(w); c(v[i], v[i + k])
}
kde_mode <- function(v) { d <- density(v); d$x[which.max(d$y)] }
manage <- function(v) {
  h <- hdi(v)
```

```
  c(mean = mean(v), median = median(v), mode_kde = kde_mode(v), sd = sd(v),
    eti_2.5 = unname(quantile(v, .025)), eti_97.5 = unname(quantile(v, .975)),
    hdi_low = h[1], hdi_high = h[2], P_gt_0 = mean(v > 0))
}
M0_RAW <- t(sapply(PRED, function(v) manage(d0[[paste0("b_z_", v)]] * SCALE$y[2] / SCALE[[v]][2])))
M0_RAW <- cbind(M0_RAW, OLS_raw_units = b_ols_raw[PRED])
BF <- d0$b_z_Froude_No * SCALE$y[2] / SCALE$Froude_No[2]

d6 <- as_draws_df(FITS$M6)
sl <- SCALE$ly[2]
EFF <- rbind(
  t(sapply(GEOM, function(v) { e <- 100 * (exp(d6[[paste0("b_z_", v)]] * sl) - 1); c(manage(e), P_abs_g
  `Residual SD multiplier per +1 SD Froude` = { e <- exp(d6$b_sigma_z_Froude_No); c(manage(e), P_abs_gt_
  `Between-hull variation (%)` = { e <- 100 * (exp(d6$sd_hull__Intercept * sl) - 1); c(manage(e), P_abs_

# kurva sigma(Froude) untuk hull tipikal
grid_df <- data.frame(Froude_No = seq(min(df$Froude_No), max(df$Froude_No), length.out = 60))
for (v in GEOM) grid_df[[v]] <- mean(df[[v]])
grid_df$Resistance <- 0; grid_df$hull_id <- 999
GRID <- FR$tf(grid_df)
SIG_GRID <- posterior_linpred(FITS$M6, newdata = GRID, dpar = "sigma", transform = TRUE, re_formula = NA

# ------------------------------------------------------------------------------
# 12. PREDIKSI HULL BARU (posterior predictive, materi Bag. 24.6)
# ------------------------------------------------------------------------------
hull_geom <- df[!duplicated(df$hull_id), GEOM]
FROUDE_GRID <- sort(unique(df$Froude_No))
scen <- data.frame(Froude_No = FROUDE_GRID)
for (v in GEOM) scen[[v]] <- median(hull_geom[[v]])
scen$Resistance <- 0; scen$hull_id <- 999
SCEN <- FR$tf(scen)
predict_new_hull <- function(fit) {
  set.seed(SEED)
  to_raw(posterior_predict(fit, newdata = SCEN, allow_new_levels = TRUE, sample_new_levels = "gaussian"
}
PRED_NEW <- predict_new_hull(FITS$M6)
MEAN_TYP <- to_raw(posterior_linpred(FITS$M6, newdata = SCEN, re_formula = NA), "log", SCALE)
PRED_TAB <- data.frame(Froude = FROUDE_GRID, pred_median = apply(PRED_NEW, 2, median),
                       PI_2.5 = apply(PRED_NEW, 2, quantile, .025), PI_97.5 = apply(PRED_NEW, 2, quanti
                       P_R_gt_5 = colMeans(PRED_NEW > 5), P_R_gt_20 = colMeans(PRED_NEW > 20))
I40 <- which(abs(FROUDE_GRID - 0.40) < 1e-9)

# ------------------------------------------------------------------------------
# 13. SENSITIVITAS: lab prior-data (analitik) & prior pada M6 (MCMC)
# ------------------------------------------------------------------------------
sigma2_known <- bn / (an - 1)
hull_order <- unique(mdl$hull_id)
SUBSETS <- list(`1 hull (n=14)` = hull_order[1], `3 hulls (n=42)` = hull_order[1:3], `22 hulls (n=308)`
PRIORS_LAB <- list(`Weak N(0, 1)` = c(0, 1), `Strong-correct N(0.81, 0.02)` = c(0.81, 0.02),
                   `Strong-wrong N(0.40, 0.02)` = c(0.40, 0.02))
LAB <- do.call(rbind, lapply(names(SUBSETS), function(sn) {
  idx <- mdl$hull_id %in% SUBSETS[[sn]]
  Xs <- X[idx, ]; ys <- y[idx]
  do.call(rbind, lapply(names(PRIORS_LAB), function(pn) {
```

```
    pr <- PRIORS_LAB[[pn]]
    m0v <- rep(0, p); m0v[p] <- pr[1]
    V0v <- diag(p); V0v[p, p] <- pr[2]^2
    Vni <- solve(V0v) + crossprod(Xs) / sigma2_known
    Vn_ <- solve(Vni)
    mn_ <- drop(Vn_ %*% (solve(V0v) %*% m0v + crossprod(Xs, ys) / sigma2_known))
    b_hat <- coef(lm(ys ~ Xs[, p]))[2]
    data.frame(data = sn, prior = pn, post_mean = mn_[p], post_sd = sqrt(Vn_[p, p]),
               data_only_slope = unname(b_hat), prior_pull = (1 / pr[2]^2) / Vni[p, p])
  }))
}))

SENS_FITS <- list(`Tighter (x0.5)` = fit_model("M6", s = 0.5, tag = "M6_prior_x0.5"),
                  `Base (x1)` = FITS$M6,
                  `Wider (x2.5)` = fit_model("M6", s = 2.5, tag = "M6_prior_x2.5"))
KEY <- c("b_z_LD_Ratio", "b_z_BD_Ratio", "b_z_LB_Ratio", "b_z_LCB", "b_z_Prismatic_Coef",
         "b_sigma_z_Froude_No", "sd_hull__Intercept")
SENS <- cache_rds("sensitivity", do.call(rbind, lapply(names(SENS_FITS), function(lab) {
  f <- SENS_FITS[[lab]]; dd <- as_draws_df(f)
  data.frame(prior = lab, param = KEY, median = sapply(KEY, function(k) median(dd[[k]])),
             lo = sapply(KEY, function(k) quantile(dd[[k]], .025)), hi = sapply(KEY, function(k) quanti
             P_R20_Fr040 = mean(predict_new_hull(f)[, I40] > 20),
             ELPD_LOO = loo_raw(f, "M6")$loo$estimates["elpd_loo", "Estimate"], row.names = NULL)
})))
NU <- as_draws_df(FITS$M5)$nu

# ------------------------------------------------------------------------------
# 14. AUDIT REPRODUCIBILITY: seed & urutan data
# ------------------------------------------------------------------------------
compare_runs <- function(fa, fb) {
  v <- MAIN_PAR(fa)
  sa <- summarise_draws(as_draws_array(fa, variable = v), "mean", "sd", "mcse_mean")
  sb <- summarise_draws(as_draws_array(fb, variable = v), "mean", "sd", "mcse_mean")
  data.frame(param = v, mean_a = sa$mean, mean_b = sb$mean, sd_a = sa$sd,
             z_mcse = (sb$mean - sa$mean) / sqrt(sa$mcse_mean^2 + sb$mcse_mean^2),
             pct_of_sd = 100 * abs(sb$mean - sa$mean) / sa$sd,
             expected_noise_pct = 100 * sqrt(2) * median(sa$mcse_mean / sa$sd))
}
SEEDS_EXTRA <- c(777, 999, 31, 123)
SEED_FITS <- c(list(`2026` = FITS$M6),
               lapply(setNames(SEEDS_EXTRA, SEEDS_EXTRA), function(s)
                 cache_rds(paste0("fit_M6_seed", s), update(FITS$M6, seed = s, refresh = 0, silent = 2,
FIT_SEED <- SEED_FITS[["777"]]
set.seed(SEED)
SHUFFLED <- mdl[sample(nrow(mdl)), ]
FIT_SHUF <- cache_rds("fit_M6_shuffled", update(FITS$M6, newdata = SHUFFLED, seed = SEED, refresh = 0,
                                                silent = 2, recompile = FALSE))
CMP_SEED <- compare_runs(FITS$M6, FIT_SEED)
CMP_ORDER <- compare_runs(FITS$M6, FIT_SHUF)
FLAGGED <- unique(c(CMP_SEED$param[abs(CMP_SEED$z_mcse) >= 3], CMP_ORDER$param[abs(CMP_ORDER$z_mcse) >=

# Audit lima seed: apakah MCSE yang dilaporkan sesuai dengan variasi nyata antar-run?
v_main <- MAIN_PAR(FITS$M6)
seed_sum <- lapply(SEED_FITS, function(f) summarise_draws(as_draws_array(f, variable = v_main), "mean",
```

```
seed_means <- sapply(seed_sum, `[[`, "mean"); rownames(seed_means) <- v_main
MULTI_SEED <- data.frame(param = v_main, t(apply(seed_means, 1, range)),
                         between_run_sd = apply(seed_means, 1, sd),
                         mean_reported_mcse = rowMeans(sapply(seed_sum, `[[`, "mcse_mean")))
names(MULTI_SEED)[2:3] <- c("min_mean_5_seeds", "max_mean_5_seeds")
MULTI_SEED$ratio_sd_to_mcse <- MULTI_SEED$between_run_sd / MULTI_SEED$mean_reported_mcse
# Kesimpulan substantif antar seed: variasi antar-hull (%) dan probabilitas eksedans hull baru
SEED_CONCL <- do.call(rbind, lapply(names(SEED_FITS), function(s) {
  dd <- as_draws_df(SEED_FITS[[s]])
  data.frame(seed = s, between_hull_pct = median(100 * (exp(dd$sd_hull__Intercept * SCALE$ly[2]) - 1)),
             P_R20_Fr040 = mean(predict_new_hull(SEED_FITS[[s]])[, I40] > 20))
}))

# ---------------------------------------------------------------------------
# 15. CROSS-VALIDATION: per hull (grouped) vs acak per baris
# ---------------------------------------------------------------------------
logmeanexp <- function(x) { m <- max(x); m + log(mean(exp(x - m))) }
make_folds <- function(scheme) {
  if (scheme == "grouped") {
    hulls <- sort(unique(full$hull_id))
    fold_of_hull <- rep(1:5, length.out = length(hulls))            # 22 hull -> fold berisi 4-5 hull u
    fold_of_hull[match(full$hull_id, hulls)]
  } else {
    set.seed(SEED); sample(rep(1:5, length.out = nrow(full)))
  }
}
cv_eval <- function(name, scheme) cache_rds(paste0("cv_", name, "_", scheme), {
  sp <- SPECS[[name]]
  resp <- if (sp$resp == "raw") "y_z" else "ly_z"
  folds <- make_folds(scheme)
  recs <- list(); rhats <- c()
  for (k in 1:5) {
    fr <- make_frames(full[folds != k, ], full[folds == k, ])
    f <- update(FITS[[name]], newdata = fr$train, chains = CV_SAMPLER$chains, iter = CV_SAMPLER$iter,
                warmup = CV_SAMPLER$warmup, seed = SEED + k, refresh = 0, silent = 2, recompile = FALSE
    rhats <- c(rhats, max(summarise_draws(as_draws_array(f, variable = MAIN_PAR(f)), "rhat")$rhat))
    ll <- log_lik(f, newdata = fr$test, allow_new_levels = TRUE, sample_new_levels = "gaussian")
    lpd <- apply(ll, 2, logmeanexp) + jacobian(fr$test, sp$resp, fr$sc)
    set.seed(SEED + k)
    yr <- to_raw(posterior_predict(f, newdata = fr$test, allow_new_levels = TRUE, sample_new_levels = "
                 sp$resp, fr$sc)
    recs[[k]] <- data.frame(fold = k, hull_id = fr$test$hull_id, Froude_No = fr$test$Froude_No,
                            y = fr$test$Resistance, pred_mean = colMeans(yr),
                            lo = apply(yr, 2, quantile, .025), hi = apply(yr, 2, quantile, .975), lpd =
  }
  r <- bind_rows(recs)
  list(pred = r, summary = data.frame(
    model = name, scheme = scheme, RMSE = sqrt(mean((r$y - r$pred_mean)^2)), MAE = mean(abs(r$y - r$pred
    coverage_95 = mean(r$y >= r$lo & r$y <= r$hi), PI_width = mean(r$hi - r$lo),
    ELPD_per_obs = mean(r$lpd), ELPD_total = sum(r$lpd), max_rhat_folds = max(rhats)))
})
CV_PLAN <- list(c("M0", "grouped"), c("M1", "grouped"), c("M2", "grouped"), c("M3", "grouped"), c("M4",
                c("M6", "grouped"), c("M4", "row-random"), c("M6", "row-random"))
CV <- lapply(CV_PLAN, function(x) cv_eval(x[1], x[2]))
```

```
names(CV) <- sapply(CV_PLAN, paste, collapse = "_")
CV_TAB <- bind_rows(lapply(CV, `[[`, "summary"))

cv_key <- function(r) paste(r$hull_id, round(r$Froude_No, 3))
grouped_models <- CV_TAB$model[CV_TAB$scheme == "grouped"]
BEST_CV <- grouped_models[which.max(CV_TAB$ELPD_total[CV_TAB$scheme == "grouped"])]
ref <- CV[[paste0(BEST_CV, "_grouped")]]$pred
PAIRED <- bind_rows(lapply(grouped_models, function(m) {
  o <- CV[[paste0(m, "_grouped")]]$pred
  o <- o[match(cv_key(ref), cv_key(o)), ]
  d <- o$lpd - ref$lpd
  hs <- tapply(d, ref$hull_id, sum)
  data.frame(model = m, ELPD_total = sum(o$lpd), elpd_diff = sum(d),
             se_diff_obs = sd(d) * sqrt(length(d)), se_diff_hull = sd(hs) * sqrt(length(hs)))
})) %>% arrange(desc(ELPD_total)) %>% mutate(diff_over_se_hull = ifelse(se_diff_hull > 0, elpd_diff / s
OPTIMISM <- bind_rows(lapply(c("M4", "M6"), function(m) {
  g <- CV[[paste0(m, "_grouped")]]$pred; r <- CV[[paste0(m, "_row-random")]]$pred
  r <- r[match(cv_key(g), cv_key(r)), ]
  d <- r$lpd - g$lpd
  data.frame(model = m, ELPD_optimism = sum(d), se = sd(d) * sqrt(length(d)),
             RMSE_grouped = sqrt(mean((g$y - g$pred_mean)^2)), RMSE_row = sqrt(mean((r$y - r$pred_mean)
})) %>% mutate(optimism_over_se = ELPD_optimism / se)

# ------------------------------------------------------------------------------
# 16. CHECKLIST & MANIFEST REPRODUCIBILITY
# ------------------------------------------------------------------------------
CHECKS <- data.frame(Item = c(
  "Seed eksplisit tercatat", "Checksum SHA-256 data mentah tercatat", "Preprocessing scripted (make_fra
  "Standardisasi dihitung di dalam fold (tanpa kebocoran)", "Prior eksplisit + prior predictive check",
  "Komputasi divalidasi (analitik vs Gibbs vs HMC, < 3 MCSE)", "Likelihood manual = likelihood Stan",
  "Semua model: R-hat <= 1.01, ESS >= 400, 0 divergence", "Stabil terhadap seed (semua |z| < 3 MCSE)",
  "Stabil terhadap urutan data (semua |z| < 3 MCSE)",
  "Kesimpulan prediktif stabil antar 5 seed (rentang P(R>20 | Fr=0.40) < 0.05)",
  "Validasi per-hull dipakai untuk klaim prediktif", "Objek fit tersimpan (fits/*.rds)"),
  Pass = c(TRUE, nchar(RAW_SHA256) == 64, TRUE, TRUE, TRUE, max(abs(COMP$HMC_minus_Analytic_in_MCSE)) <
           isTRUE(all.equal(LL_CHECK[["manual"]], LL_CHECK[["stan"]])), all(DIAG$verdict == "OK"),
           all(abs(CMP_SEED$z_mcse) < 3), all(abs(CMP_ORDER$z_mcse) < 3),
           diff(range(SEED_CONCL$P_R20_Fr040)) < 0.05, TRUE, file.exists("fits/M6.rds")))

# ------------------------------------------------------------------------------
# Export CSV yang kompatibel dengan semua versi R:
# write.table()/write.csv() tidak dapat menulis kolom bertipe list.
# Hasil analisis tetap sama; bagian ini hanya mengubah cara file CSV disimpan.
# ------------------------------------------------------------------------------
safe_csv <- function(x, file) {
  x <- as.data.frame(x, stringsAsFactors = FALSE)

  for (j in seq_along(x)) {
    if (is.factor(x[[j]])) {
      x[[j]] <- as.character(x[[j]])
    } else if (is.list(x[[j]])) {
      x[[j]] <- vapply(
        x[[j]],
        function(v) {
```

```
          if (length(v) == 0L || all(is.na(v))) return("")
          paste(as.character(unlist(v, use.names = FALSE)), collapse = "; ")
        },
        character(1)
      )
    }
  }

  utils::write.csv(x, file, row.names = FALSE, na = "")
}

safe_csv(CV_TAB, "cv_results.csv")
safe_csv(LOO_TAB, "model_comparison_loo.csv")
MANIFEST <- list(
  seed = SEED, raw_data_sha256 = RAW_SHA256, R = R.version.string,
  packages = sapply(c("brms", "rstan", "loo", "posterior", "dplyr", "splines"), function(x) as.characte
  sampler = SAMPLER, cv_sampler = CV_SAMPLER, control = CONTROL,
  scaling_full_data = SCALE, diagnostics = DIAG, loo = LOO_TAB[, c("model", "elpd_loo", "elpd_diff", "s
  cv = CV_TAB, multi_seed = MULTI_SEED, seed_conclusions = SEED_CONCL, checks = CHECKS)
jsonlite::write_json(MANIFEST, "reproducibility_manifest_R.json", pretty = TRUE, auto_unbox = TRUE, dig
```